Università degli Studi di Torino

Dipartimento di informatica



Tesi di Laurea Triennale in Informatica

Classificazione ibrida classico-quantistica delle morfologie galattiche: confronto tra bottleneck classici e circuiti quantistici variazionali

Relatore:

Prof. Luca Paolini

Candidato:

Michele Scandone

Matricola 1096271

ANNO ACCADEMICO 2025/2026

Abstract

This thesis investigates hybrid classical–quantum transfer learning for galaxy morphology classification. A balanced dataset of 5,628 SDSS images, labelled using Galaxy Zoo classifications, supports a binary task distinguishing elliptical and spiral galaxies and a three-class task that additionally includes systems labelled as mergers. A frozen, ImageNet-pretrained ResNet18 provides a shared representation for classical heads and hybrid heads with four or eight simulated qubits. The main comparison pairs the trainable quantum head with a classical bottleneck of the same dimension; a frozen-circuit variant assesses the contribution of training the circuit parameters.

The evaluation comprises 640 runs across ten stratified holdout repetitions and four training regimes: 100, 300, 900 images and the complete training split. Nested training subsets and shared validation and test sets support paired comparisons. Macro-F1, bootstrap confidence intervals and Holm-adjusted tests are complemented by per-class analysis, probabilistic metrics and computational costs.

On the *Full* binary task, the models achieve a Macro-F1 close to 0.96, with no statistically supported advantage for the quantum head over the matched classical control. On the *Full* three-class task, the quantum head has a lower mean Macro-F1 by 0.73 and 1.67 percentage points with four and eight qubits, respectively. Reduced-data regimes do not reveal a quantum advantage under the adopted protocol, while simulation requires substantially more training time. The study provides a reproducible benchmark that distinguishes predictive performance from the added value of the quantum component and identifies concrete directions for further investigation. Its conclusions concern the tested architectures and simulation conditions, not quantum machine learning in general.

Dichiaro di essere responsabile del contenuto dell'elaborato che presento al fine del conseguimento del titolo, di non avere plagiato in tutto o in parte il lavoro prodotto da altri e di aver citato le fonti originali in modo congruente alle normative vigenti in materia di plagio e di diritto d'autore. Sono inoltre consapevole che nel caso la mia dichiarazione risultasse mendace, potrei incorrere nelle sanzioni previste dalla legge e la mia ammissione alla prova finale potrebbe essere negata.

Indice

1 Introduzione **5**
1.1 Contesto e motivazione 5
1.2 Problema affrontato e obiettivo del lavoro 5
1.3 Approccio sperimentale e contributi 7
1.4 Domande di ricerca 8
1.5 Organizzazione della tesi 8

2 Contesto scientifico e fondamenti teorici **11**
2.1 Classificazione morfologica delle galassie 11
2.2 Apprendimento profondo e transfer learning 13
2.3 Fondamenti di calcolo quantistico 14
2.4 Reti neurali ibride classico-quantistiche 15
2.5 Potenzialità, limiti e criteri di confronto 18
2.6 Lavori correlati e posizionamento della tesi 18

3 Dataset e protocollo di validazione **21**
3.1 Provenienza dei dati e popolazione selezionata 21
3.2 Assegnazione delle etichette 22
3.3 Pulizia, acquisizione e bilanciamento 23
3.4 Caratteristiche del campione e trasformazioni 24
3.5 Task e repeated holdout stratificato 27
3.6 Regimi a ridotta disponibilità di dati 28
3.7 Tracciabilità e perimetro delle conclusioni 29

4 Modelli e disegno sperimentale **31**
4.1 Impostazione del confronto 31
4.2 Teste classiche 32
4.3 Classificatore ibrido e circuito variazionale 33
4.4 Numero di parametri e controlli di appaiamento 37
4.5 Addestramento e selezione del modello 38
4.6 Matrice sperimentale e gerarchia delle analisi 40
4.7 Metriche di valutazione 40
4.8 Confronti appaiati e incertezza 43
4.9 Costo computazionale e riproducibilità 44

5 Risultati **47**
5.1 Completezza degli esperimenti e convenzioni di lettura 47
5.2 Prestazioni assolute e numerosità del training 48
5.3 Confronto appaiato Q–B2 49

5.4 Passaggio dal binario alle tre classi 51
5.5 Analisi della classe merger 53
5.6 Addestramento quantistico e dimensionalità 54
5.7 Qualità delle probabilità e calibrazione 56
5.8 Prestazioni e costo computazionale 57
5.9 Sintesi delle evidenze 58

6 Discussione **61**
6.1 Confronto principale e ruolo della rappresentazione 61
6.2 Complessità del task e classe merger 62
6.3 Disponibilità dei dati e regimi low-resource 62
6.4 Addestramento circuitale e numero di qubit 63
6.5 Qualità probabilistica e costo computazionale 63
6.6 Relazione con la letteratura 64
6.7 Limiti e minacce alla validità 64
6.8 Sintesi interpretativa 65

7 Conclusioni e sviluppi futuri **67**
7.1 Sintesi del lavoro 67
7.2 Contributi e valore del confronto 67
7.3 Sviluppi futuri 68
7.4 Considerazione conclusiva 69

A Query di estrazione del catalogo **71**

B Codice del confronto appaiato **73**

Capitolo 1

Introduzione

1.1 Contesto e motivazione

La disponibilità di immagini astronomiche rende possibile studiare le popolazioni galattiche su campioni estesi, ma richiede strumenti capaci di organizzare e interpretare grandi quantità di osservazioni. La morfologia costituisce uno degli elementi di questa analisi: distinguere strutture regolari, dischi e sistemi perturbati contribuisce alla caratterizzazione delle galassie e allo studio della loro evoluzione. L'ispezione visuale resta un riferimento importante, ma la crescita dei cataloghi richiede lo sviluppo di procedure automatiche.

Galaxy Zoo ha mostrato come la partecipazione di numerosi classificatori possa produrre annotazioni morfologiche utilizzabili per analisi su larga scala [13]. Su queste basi, le reti neurali convoluzionali consentono di apprendere direttamente dalle immagini rappresentazioni utili al riconoscimento [6]. Il problema non si esaurisce però nel raggiungimento di un punteggio Macro-F1 elevato: occorre comprenderne la stabilità, la dipendenza dai dati disponibili e il costo necessario per ottenerlo.

In questo contesto si colloca l'interesse per il quantum machine learning. I modelli ibridi combinano elaborazioni classiche e circuiti quantistici parametrizzati. Il transfer learning offre un collegamento pratico tra immagini ad alta dimensionalità e registri quantistici di piccole dimensioni: una rete preaddestrata estrae le feature e una testa ibrida le utilizza per classificare [15]. Tuttavia la possibilità di costruire un simile modello non dimostra che il circuito aggiunga un beneficio rispetto a un'alternativa classica.

In questa tesi sperimento il contributo della componente quantistica alla classificazione morfologica delle galassie. Il confronto con teste classiche permette di valutarne i possibili benefici insieme ai costi e ai limiti, senza assumere in partenza un vantaggio.

1.2 Problema affrontato e obiettivo del lavoro

Il dataset finale comprende 5 628 immagini, distribuite equamente tra galassie ellittiche, spirali e sistemi classificati come merger. Tutti i modelli vengono valutati su due problemi: un task binario, limitato a ellittiche e spirali, e un task a tre classi, che comprende anche i merger. Questa seconda configurazione permette di estendere il confronto a una categoria caratterizzata da strutture perturbate e potenzialmente ambigue, verificando come cambino le prestazioni rispetto al problema

binario. Il passaggio tra i due task non isola tuttavia un effetto causale della sola classe aggiunta, poiché modifica anche la composizione del campione e il problema di classificazione.

Per affrontare l'analisi automatica delle immagini vengono utilizzate le reti neurali convoluzionali (*Convolutional Neural Networks*, CNN). Questi modelli elaborano regioni locali dell'immagine mediante filtri appresi durante l'addestramento, condividendo gli stessi parametri nelle diverse posizioni spaziali. La composizione di più strati consente di costruire rappresentazioni gerarchiche, dalle caratteristiche visive locali a strutture progressivamente più articolate. Il loro impiego nella classificazione morfologica delle galassie è illustrato, per esempio, dal lavoro di Dieleman et al. [6].

Tra le architetture convoluzionali, le reti residuali (*Residual Networks*, ResNet) introducono connessioni che sommano l'ingresso di un blocco al risultato delle trasformazioni apprese, facilitando l'ottimizzazione di reti profonde [10]. In questa tesi viene utilizzata una ResNet18 preaddestrata su ImageNet come estrattore di caratteristiche, detto *backbone*. Il suo classificatore finale viene rimosso e i pesi restano congelati, cioè non vengono aggiornati sul dataset galattico.

Per ogni immagine, il backbone produce un vettore di 512 valori numerici, chiamati *feature*, che rappresenta le caratteristiche visive estratte. Questi vettori vengono precalcolati una volta per tutte e forniti alle diverse *teste di classificazione*: le componenti che trasformano le feature nei punteggi delle classi. Il confronto riguarda quindi classificatori che ricevono la stessa rappresentazione delle immagini, non CNN addestrate separatamente.

Sono considerate cinque famiglie di teste.

- **B0**: un classificatore affine che trasforma direttamente le 512 feature nei punteggi delle classi; Vedere Sezione 4.2.1.
- **B1**: un percettrone multistrato, che introduce uno strato nascosto e una trasformazione non lineare prima della classificazione; Vedere Sezione 4.2.2.
- **B2**: un controllo classico che proietta le feature in quattro oppure otto componenti, applica la trasformazione $\pi \tanh$ e utilizza un classificatore affine finale. Questa rappresentazione intermedia ridotta costituisce il *bottleneck*, o collo di bottiglia; Vedere Sezione 4.2.3.
- **Q**: una testa ibrida che utilizza una proiezione iniziale analoga a B2 e codifica le componenti ottenute mediante rotazioni di quattro oppure otto qubit. Un circuito quantistico addestrabile elabora gli stati così preparati; i valori attesi delle misure vengono poi forniti a un classificatore affine; Vedere Sezione 4.3.
- **QF**: una testa con la stessa struttura di Q, nella quale i parametri del circuito rimangono fissi ai valori iniziali. La proiezione iniziale e il classificatore finale restano invece addestrabili: QF non è quindi una rete interamente congelata. Vedere Sezione 4.3.4.

Le cinque famiglie danno origine a otto configurazioni: B0 e B1 sono utilizzate ciascuna in una configurazione, mentre B2, Q e QF vengono valutate sia con quattro sia con otto componenti o qubit. Le architetture e i rispettivi parametri sono descritti nel Capitolo 4.

Il confronto Q–B2 valuta il contributo dell'inserimento del circuito quantistico rispetto a un controllo classico con la stessa dimensione del bottleneck. Il confronto

Q–QF esamina invece il contributo dell'addestramento dei parametri circuitali. B0 e B1 forniscono ulteriori riferimenti classici.

L'obiettivo del lavoro è stabilire se, nel protocollo considerato, l'inserimento del circuito migliori la classificazione e se il suo contributo vari con il task e con la disponibilità dei dati di training. La scelta dei controlli e delle ablazioni è quindi parte integrante della domanda scientifica, non soltanto uno strumento per ordinare i modelli in base alle prestazioni [3].

1.3 Approccio sperimentale e contributi

La valutazione utilizza dieci ripetizioni di holdout stratificato: per ciascuna ripetizione, i dati vengono suddivisi in training, validation e test, mantenendo le proporzioni delle classi. Il training viene utilizzato per apprendere i parametri, la validation per selezionare il modello e il test per valutarne le prestazioni. I dettagli del protocollo sono descritti nel Capitolo 3.

Per ogni ripetizione vengono considerati quattro regimi di disponibilità dei dati di addestramento. Il regime denominato *Full* utilizza tutti gli esempi assegnati al training: 1 876 immagini nel task binario e 2 814 nel task a tre classi. Nei regimi ridotti, l'addestramento utilizza invece 100, 300 oppure 900 immagini selezionate dalla stessa porzione di dati del regime *Full*. Validation e test rimangono invariati tra i quattro regimi della medesima ripetizione e non vengono utilizzati per aggiornare i pesi dei modelli. La combinazione di due task, otto configurazioni, quattro regimi e dieci seed produce complessivamente 640 run, ossia esecuzioni di addestramento e valutazione.

La metrica principale è la Macro-F1 [19], definita come la media aritmetica degli F1-score calcolati separatamente per ciascuna classe. L'F1-score combina precision e recall attraverso la loro media armonica: la precision misura la proporzione di assegnazioni corrette tra quelle effettuate a una classe, mentre il recall misura la proporzione di esempi reali di quella classe riconosciuti correttamente. La media macro assegna lo stesso peso a ciascuna classe; valori più elevati indicano prestazioni migliori. La valutazione comprende inoltre metriche per classe, misure della qualità delle probabilità predette e tempi di esecuzione.

Il confronto tra modelli è appaiato: le differenze di prestazione vengono calcolate entro ciascuna ripetizione, a parità di dati di addestramento e valutazione. Per descrivere l'incertezza delle stime vengono costruiti intervalli bootstrap al 95%. La procedura estrae con reinserimento dai dieci risultati disponibili 10 000 campioni, ciascuno composto da dieci osservazioni: uno stesso risultato può comparire più volte, mentre altri possono essere esclusi. Su ogni campione viene ricalcolata la quantità di interesse, come la media della Macro-F1. Nel confronto tra due modelli vengono invece ricampionate le dieci differenze appaiate e ne viene calcolata la media. Non sono quindi necessari nuovi addestramenti. I percentili 2,5% e 97,5% delle stime ricampionate definiscono i limiti dell'intervallo. Quest'ultimo descrive l'incertezza della quantità stimata, non l'intervallo che contiene il 95% delle singole run.

I test statistici sono affiancati dalla correzione di Holm, che tiene conto dell'esecuzione di più confronti e controlla il rischio di ottenere almeno un falso positivo all'interno di ciascuna famiglia di test, purché siano rispettate le assunzioni dei test di partenza. Né questa correzione né il bootstrap semplice eliminano la dipenden-

za dovuta al riuso del dataset nelle diverse ripetizioni. Le relative limitazioni sono esplicitate nella descrizione del metodo e nella discussione.

Il lavoro svolto comprende la costruzione del dataset, l'implementazione dei modelli e la loro valutazione. La pipeline conserva il collegamento tra immagini, partizioni e predizioni, rendendo tracciabili i risultati. Il confronto tra le teste permette di esaminare il ruolo della compressione, dell'inserimento del circuito quantistico e dell'addestramento dei suoi parametri attraverso controlli dedicati. L'analisi su due task e quattro regimi di dati consente inoltre di osservare come cambino gli errori e il costo computazionale al variare del problema e della disponibilità di esempi.

Le esecuzioni quantistiche utilizzano un simulatore classico, non un processore quantistico fisico (*Quantum Processing Unit*, QPU). Il lavoro valuta pertanto le architetture nel protocollo considerato e non affronta un'accelerazione computazionale eventuale su hardware quantistico. Analogamente, i risultati ottenuti su questo campione non vengono interpretati come conclusioni universali sul quantum machine learning.

1.4 Domande di ricerca

Il lavoro è organizzato attorno a cinque domande:

RQ1 — **Confronto principale.** Il modello ibrido Q migliora la Macro-F1 rispetto a B2 con bottleneck della stessa dimensione?

RQ2 — **Complessità del task.** Come cambia il divario Q–B2 passando dalla classificazione binaria a quella a tre classi, e quale ruolo descrittivo hanno gli errori sulla classe merger?

RQ3 — **Disponibilità dei dati.** Come variano le prestazioni e il confronto Q–B2 utilizzando 100, 300 e 900 immagini di training rispetto al training set completo?

RQ4 — **Contributo del circuito.** Quale beneficio si osserva addestrando i parametri quantistici rispetto a mantenerli congelati? Come cambiano le prestazioni passando da quattro a otto dimensioni/qubit?

RQ5 — **Costo computazionale.** Quale compromesso tra prestazioni e tempi di training e inferenza emerge rispetto al controllo classico?

Queste domande non hanno tutte lo stesso ruolo inferenziale. Il confronto Q–B2 sul *Full* costituisce la famiglia primaria, quello sui subset la famiglia secondaria. Le analisi per classe, Q–QF, dimensionalità, calibrazione e costo completano il quadro con funzione esplorativa, senza moltiplicare indiscriminatamente i test tra tutte le architetture.

1.5 Organizzazione della tesi

Il Capitolo 2 introduce il contesto astronomico, il transfer learning e i fondamenti delle reti ibride. Il Capitolo 3 descrive la selezione dei dati, le etichette e il protocollo di partizionamento. Il Capitolo 4 specifica architetture, addestramento e strumenti

di valutazione. Il Capitolo 5 presenta le evidenze quantitative; il Capitolo 6 ne interpreta il significato e le limitazioni. Infine, il Capitolo 7 riassume i contributi e delinea gli sviluppi futuri.

Capitolo 2

Contesto scientifico e fondamenti teorici

Per descrivere il confronto tra reti classiche e ibride occorre partire dall'informazione contenuta nelle immagini e dal modo in cui viene rappresentata. Il Capitolo introduce le categorie morfologiche, il transfer learning e le operazioni quantistiche utilizzate nel modello. La costruzione del campione e le scelte sperimentali sono trattate separatamente nei Capitoli 3 e 4.

2.1 Classificazione morfologica delle galassie

2.1.1 Informazione morfologica e classi considerate

La morfologia descrive l'aspetto e l'organizzazione delle strutture visibili di una galassia. Il suo studio contribuisce a caratterizzare le popolazioni galattiche e a indagarne formazione ed evoluzione. La classificazione da immagini riguarda però una proiezione osservata del sistema, non una ricostruzione completa delle sue proprietà fisiche.

Un riferimento importante in questo ambito è Galaxy Zoo, un progetto di *citizen science*, cioè di ricerca scientifica basata sulla partecipazione di volontari. Attraverso un'interfaccia online, i partecipanti esaminano immagini di galassie e ne classificano l'aspetto visivo. La prima fase del progetto, Galaxy Zoo 1, ha raccolto classificazioni per quasi 900 000 galassie osservate dallo Sloan Digital Sky Survey (SDSS) [13]. Le valutazioni di più partecipanti vengono aggregate per descrivere il consenso sulla classificazione di ciascun oggetto. Da queste informazioni derivano le etichette utilizzate nella tesi, secondo i criteri presentati nel Capitolo 3.

Nel contesto della tesi si considerano tre categorie operative. Le galassie *ellittiche* presentano generalmente una distribuzione della luminosità relativamente regolare, senza bracci a spirale chiaramente riconoscibili. Le galassie *spirali* mostrano una struttura a disco nella quale possono essere visibili bracci e una componente centrale. L'aspetto osservato dipende anche dall'orientamento: una galassia a disco vista di taglio non mostra i bracci nello stesso modo di una vista frontalmente. La categoria *merger* identifica invece sistemi classificati come associati a un'interazione o fusione, che possono mostrare componenti multiple, asimmetrie e strutture perturbate.

La Figura 2.1 mostra un esempio per ciascuna delle tre categorie considerate. Nell'immagine della galassia ellittica si osserva una distribuzione luminosa relativa-



(a) Ellittica (b) Spirale (c) Sistema etichettato merger

Figura 2.1: Esempi reali del dataset derivato da immagini SDSS e classificazioni Galaxy Zoo. Sono mostrati ritagli centrali di 224 × 224 pixel, senza sovrapposizioni interpretative. Gli identificativi degli oggetti sono, da sinistra, `1237656241699881339`, `1237651273507668077` e `1237655499209310435`. Gli esempi sono illustrativi, non prototipi esaustivi delle classi; l'etichetta merger non costituisce da sola una conferma fisica di fusione.

mente regolare, mentre nella spirale è riconoscibile una struttura a disco con bracci. L'esempio etichettato come merger presenta una struttura più perturbata. Le immagini illustrano la varietà morfologica del campione, senza rappresentare in modo esaustivo tutte le possibili configurazioni di ciascuna classe.

2.1.2 Survey, annotazioni e difficoltà del riconoscimento

Le survey astronomiche producono raccolte di immagini per le quali l'ispezione individuale non è facilmente scalabile. Galaxy Zoo ha affrontato il problema coinvolgendo volontari nella classificazione delle immagini SDSS; il rilascio Galaxy Zoo 1 rende disponibili classificazioni morfologiche aggregate per un ampio campione di galassie [13]. Le frazioni di voto descrivono le risposte dei classificatori e il loro accordo: non vanno identificate automaticamente con probabilità fisiche certe di appartenenza a una classe.

Risoluzione, rapporto segnale-rumore, orientamento e presenza di sorgenti vicine influenzano ciò che è riconoscibile nell'immagine. Inoltre, una distribuzione luminosa perturbata può essere più difficile da descrivere con una singola etichetta. Ciò motiva l'uso della classe merger come ulteriore banco di prova, senza assumere a priori che essa debba essere sempre la più difficile da classificare per qualsiasi architettura delle reti usate nella tesi.

Il passaggio da due a tre classi modifica sia le decisioni richieste sia la composizione del problema. Non equivale a modificare un solo parametro di difficoltà mantenendo invariato tutto il resto. Soglie di voto, bilanciamento e separazione degli oggetti tra training e test devono quindi essere esplicitati, come avviene nel Capitolo 3.

2.2 Apprendimento profondo e transfer learning

2.2.1 Reti convoluzionali e rappresentazioni delle immagini

Una rete convoluzionale (CNN) elabora un'immagine mediante filtri applicati a regioni locali, condividendo gli stessi pesi tra posizioni diverse. Le uscite sono mappe di attivazione: ciascun canale risponde a determinati pattern appresi durante l'addestramento. La composizione di strati convoluzionali e trasformazioni non lineari consente di combinare informazioni locali in rappresentazioni progressivamente più elaborate.

Non è necessario definire manualmente una misura per ogni possibile struttura morfologica. Tuttavia, non è neppure corretto attribuire automaticamente a ogni attivazione un significato astronomico preciso: una feature appresa può mescolare forma, colore, tessitura e informazioni legate al processo osservativo. L'impiego delle CNN classiche nella classificazione galattica è esemplificato da Dieleman et al. [6], che incorporano le simmetrie delle immagini nel modello di riconoscimento.

Una distinzione utile è quella tra *estrattore di feature*, che trasforma l'immagine in una rappresentazione, e *testa di classificazione*, che usa tale rappresentazione per produrre i punteggi delle classi. Questa separazione permette di studiare teste diverse senza modificare ogni volta l'intero sistema di visione.

2.2.2 Reti residuali e ResNet18

Le reti residuali introducono collegamenti che sommano l'ingresso di un blocco alla trasformazione appresa dal blocco stesso [10]. Quando le dimensioni coincidono, il principio è espresso da

$$\boldsymbol{y} = F(\boldsymbol{x}; \boldsymbol{w}) + \boldsymbol{x}. \tag{2.1}$$

Il blocco apprende così una correzione rispetto alla rappresentazione in ingresso. Quando cambiano le dimensioni, il collegamento può includere una proiezione. Queste connessioni facilitano l'ottimizzazione di reti profonde, senza garantire da sole una migliore generalizzazione per qualunque dataset.

ResNet18 è una variante relativamente compatta della famiglia. Eliminando il classificatore finale si ottiene, dopo l'aggregazione spaziale delle mappe, un vettore di 512 componenti. Nel presente lavoro questa rappresentazione costituisce il punto di partenza comune dei modelli. Il numero 512 indica la dimensione del vettore, non un elenco di 512 proprietà fisiche delle galassie note a priori.

2.2.3 Preaddestramento, congelamento e fine-tuning

Il transfer learning riutilizza una rappresentazione appresa su un problema sorgente per affrontarne un altro. È possibile aggiornare anche i pesi dell'estrattore sul nuovo dataset, effettuando *fine-tuning*, oppure mantenerli fissi e addestrare soltanto la testa. La seconda strategia riduce il numero di parametri da stimare e consente di riutilizzare le feature già calcolate. In questa tesi viene adottata la seconda strategia: la ResNet18 preaddestrata su ImageNet (un ampio dataset di immagini organizzate in categorie semantiche, come animali, veicoli e oggetti di uso comune) viene mantenuta congelata e utilizzata per estrarre le 512 feature di ciascuna immagine. Il trasferimento al dominio galattico avviene attraverso gli strati successivi.

Di conseguenza, la componente quantistica riceve feature classiche compresse, non direttamente i pixel dell'immagine.

Il riuso di feature apprese su immagini naturali non implica che esse siano ottimali per immagini astronomiche. È una scelta sperimentale che introduce un limite, ma permette anche un confronto più controllato: le differenze tra teste non dipendono da backbone addestrati separatamente.

2.3 Fondamenti di calcolo quantistico

Si richiamano qui le nozioni del modello a circuito necessarie per leggere l'architettura ibrida. Per una trattazione sistematica di stati, porte e misure si rimanda a Nielsen e Chuang [18].

2.3.1 Qubit e registri quantistici

Un qubit è descritto, nel caso di uno stato puro, da un vettore normalizzato in uno spazio complesso bidimensionale:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \qquad \alpha, \beta \in \mathbb{C}, \qquad |\alpha|^2 + |\beta|^2 = 1. \tag{2.2}$$

I vettori $|0\rangle$ e $|1\rangle$ formano la base computazionale. Una misura in questa base restituisce 0 oppure 1, con probabilità rispettivamente $|\alpha|^2$ e $|\beta|^2$. La sovrapposizione descrive lo stato prima della misura: non significa poter leggere simultaneamente entrambi i valori come due bit classici.

Per q qubit lo spazio degli stati è il prodotto tensoriale degli spazi dei singoli qubit e ha dimensione 2^q. Uno stato puro generale è

$$|\psi\rangle = \sum_{z=0}^{2^q-1} c_z|z\rangle, \qquad \sum_z |c_z|^2 = 1. \tag{2.3}$$

La crescita dello spazio delle ampiezze è importante, ma non dimostra un vantaggio nell'apprendimento: preparazione dello stato, trasformazioni realizzabili e modalità di misurazione limitano l'informazione accessibile.

2.3.2 Porte, rotazioni ed entanglement

Nel modello ideale a circuito, le porte trasformano lo stato mediante operatori unitari. Le rotazioni impiegate in questa tesi sono

$$R_Y(\theta) = \begin{pmatrix} \cos(\theta/2) & -\sin(\theta/2) \\ \sin(\theta/2) & \cos(\theta/2) \end{pmatrix}, \qquad R_Z(\phi) = \begin{pmatrix} e^{-i\phi/2} & 0 \\ 0 & e^{i\phi/2} \end{pmatrix}. \tag{2.4}$$

Applicata allo stato $|0\rangle$, la rotazione $R_Y(\theta)$ produce

$$R_Y(\theta)|0\rangle = \cos(\theta/2)|0\rangle + \sin(\theta/2)|1\rangle :$$

il parametro classico a controlla quindi le ampiezze dello stato. La rotazione $R_Z(b)$ modifica invece le fasi delle componenti nella base computazionale, senza modificarne direttamente le probabilità di misura in tale base. Su una sovrapposizione, la variazione della fase relativa può influenzare le probabilità osservate dopo ulteriori

operazioni che mescolano le componenti dello stato. Applicata al solo $|0\rangle$, introduce invece una fase globale, priva di conseguenze osservabili [18].

La porta CNOT coinvolge un qubit di controllo e uno bersaglio:

$$\mathrm{CNOT}\,|c,t\rangle = |c, t \oplus c\rangle, \qquad c,t \in \{0,1\}, \tag{2.5}$$

dove $\oplus$ è la somma modulo due. Su opportune sovrapposizioni può generare entanglement. Per uno stato puro, questo significa che lo stato congiunto non è esprimibile come prodotto degli stati dei singoli sottosistemi. La presenza di una CNOT non garantisce però che ogni input generi uno stato entangled, né che tali correlazioni migliorino la classificazione.

2.3.3 Misure e valori attesi

Per usare il circuito in un classificatore occorre ottenere uscite numeriche. La misura dell'osservabile di Pauli $Z = \mathrm{diag}(1,-1)$ ha esiti $+1$ e -1. Il suo valore atteso sul qubit i è

$$z_i = \langle\psi|Z_i|\psi\rangle = P_i(0) - P_i(1), \qquad z_i \in [-1,1], \tag{2.6}$$

dove Z_i agisce sul qubit considerato e come identità sugli altri. Leggendo un'osservabile per qubit si ottiene un vettore reale [18] di dimensione q, senza ricostruire tutte le 2^q ampiezze.

Su hardware quantistico, un valore atteso è normalmente stimato ripetendo preparazione e misura per un numero finito di esecuzioni, dette *shot*. Una simulazione ideale dello stato può invece calcolarlo direttamente, senza rumore di campionamento delle misure. Questa distinzione è essenziale e ha conseguenze sull'addestramento e sulla valutazione dei costi. Nel simulatore utilizzato, i valori attesi sono calcolati senza campionamento delle misure e quindi senza il rumore statistico associato a un numero finito di esecuzioni. Su un dispositivo quantistico, invece, tali valori devono essere stimati mediante misurazioni ripetute: le stime presentano un'incertezza che può influenzare anche il calcolo della perdita e dei gradienti. I tempi misurati in questa tesi descrivono pertanto il costo della simulazione classica, non quello dell'esecuzione su hardware quantistico.

2.4 Reti neurali ibride classico-quantistiche

2.4.1 Encoding delle feature

Un circuito destinato a elaborare dati classici richiede una mappa di codifica. Nell'*angle encoding* [15] le componenti di un vettore determinano gli angoli delle porte. Per esempio,

$$|\phi(\boldsymbol{a})\rangle = \left[\bigotimes_{i=1}^{q} R_Y(a_i)\right] |0\rangle^{\otimes q}. \tag{2.7}$$

La codifica non assegna una classe a ciascun qubit: tutti i valori in uscita possono contribuire alla decisione su ciascuna classe.

La Figura 2.2 mostra come il valore classico a_i determini l'orientamento del vettore di Bloch nel piano xz. A ogni componente del vettore di ingresso corrisponde una rotazione sul rispettivo qubit: la figura illustra quindi il singolo elemento della codifica applicata all'intero registro.

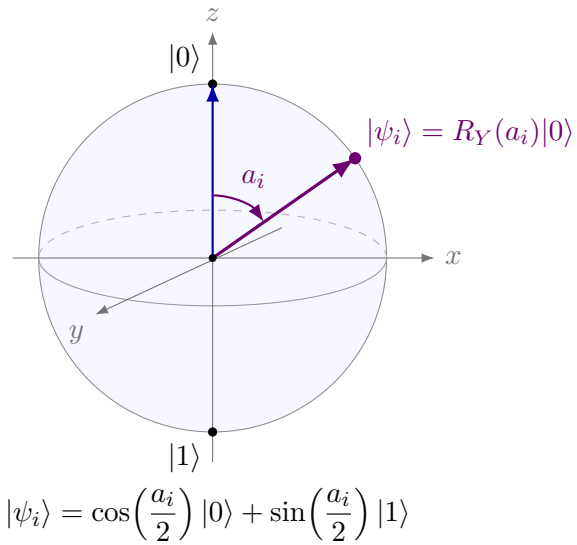


Figura 2.2: Angle encoding mediante una rotazione $R_Y(a_i)$ sulla sfera di Bloch. Sono rappresentati lo stato iniziale $|0\rangle$ e quello successivo alla codifica, per un angolo positivo illustrativo. La rappresentazione riguarda un singolo qubit prima dell'entanglement.

Quando le feature iniziali sono più numerose dei qubit, una trasformazione classica può comprimerle e limitarne l'intervallo prima dell'encoding. Nel modello della tesi, questa proiezione è addestrabile e trasforma le 512 feature in quattro oppure otto angoli. La rappresentazione risultante va distinta dall'*amplitude encoding*, nel quale i dati sono codificati nelle ampiezze di uno stato normalizzato. Le strategie comportano operazioni e costi diversi e non sono intercambiabili senza modificare il modello.

2.4.2 Circuiti variazionali e architettura ibrida

Un circuito variazionale applica una trasformazione $U(\boldsymbol{\theta})$ con parametri regolabili. La disposizione delle porte e dei collegamenti, detta *ansatz*, definisce la famiglia di trasformazioni esplorata durante il training. È utile distinguere gli angoli $\boldsymbol{\theta}$, ricavati dall'immagine in ingresso, dai parametri $\boldsymbol{a}$, condivisi tra gli esempi e aggiornati dall'ottimizzatore nel modello Q.

Nel paradigma ibrido, una componente classica prepara gli ingressi del circuito e un'altra ne elabora i risultati delle misurazioni. Mari et al. [15] descrivono questo schema nel contesto del transfer learning. La Figura 2.3 ne riassume il funzionamento: l'immagine attraversa un estrattore congelato, una proiezione classica, un blocco quantistico e un classificatore finale. Il dettaglio inferiore separa le tre operazioni del blocco quantistico: codifica degli ingressi, trasformazione variazionale e calcolo dei valori attesi.

Indicando con x l'immagine in ingresso, la composizione delle operazioni si scrive come

$$\boldsymbol{\ell}(x) = h_{\boldsymbol{\omega}}\left(\boldsymbol{z}_{\boldsymbol{\theta}}\left(g_{\boldsymbol{\eta}}\left(F_{\text{pre}}(x)\right)\right)\right), \tag{2.8}$$

dove F_{pre} è l'estrattore preaddestrato e congelato; $g_{\boldsymbol{\eta}}$ trasforma le feature negli angoli di ingresso, attraverso parametri classici $\boldsymbol{\eta}$; $\boldsymbol{z}_{\boldsymbol{\theta}}$ associa agli angoli il vettore dei valori attesi ottenuti dal circuito; $h_{\boldsymbol{\omega}}$ è il classificatore finale, con parametri classici $\boldsymbol{\omega}$.

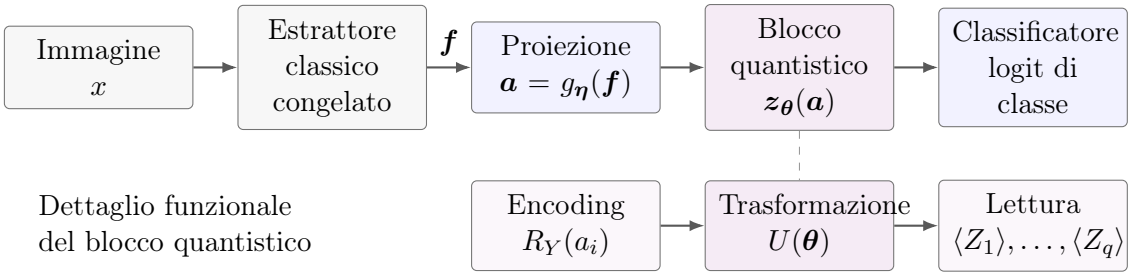


Figura 2.3: Schema concettuale di un classificatore ibrido con estrattore congelato. Il dettaglio inferiore distingue encoding dipendente dai dati, trasformazione variazionale e lettura. Si tratta di uno schema funzionale, non del circuito specifico implementato, descritto nel Capitolo 4.

Le componenti di $\boldsymbol{\ell}$ sono punteggi, detti *logit*, convertibili in probabilità mediante la funzione softmax. I valori attesi delle osservabili quantistiche non rappresentano quindi direttamente le probabilità delle classi. Nel modello Q vengono ottimizzati congiuntamente $\boldsymbol{\eta}$, $\boldsymbol{\theta}$ e $\boldsymbol{\omega}$, mentre i pesi dell'estrattore rimangono fissi.

2.4.3 Addestramento e circuito congelato

La funzione di perdita confronta le predizioni con le etichette e guida l'aggiornamento dei parametri addestrabili. Per ottimizzare la proiezione classica occorre derivare la perdita anche rispetto agli ingressi del circuito. La catena di derivate collega quindi componenti classiche e quantistiche; non si tratta di addestrare due classificatori indipendenti.

Su simulatori differenziabili è possibile usare la differenziazione automatica. Su hardware, per opportune porte parametrizzate, regole come il *parameter-shift* permettono di ricavare derivate da valutazioni del circuito con parametri traslati [18]. Le due modalità non hanno lo stesso costo operativo; quella effettivamente adottata è precisata nel Capitolo 4.

Congelare $\boldsymbol{a}$ lascia invece fissa la trasformazione circuitale. Il modello può continuare ad apprendere attraverso $\boldsymbol{\eta}$ e $\boldsymbol{\omega}$, e le uscite del circuito continuano a cambiare al cambiare dell'input. Questo controllo consente di distinguere il contributo dell'inserimento del circuito da quello dell'ottimizzazione dei suoi pesi.

2.4.4 Simulazione e processori quantistici

La simulazione classica consente di valutare il comportamento matematico di un circuito, ma non ne riproduce necessariamente il costo su un processore quantistico. Una simulazione generica a vettore di stato memorizza 2^q ampiezze complesse; il costo dipende anche dal numero e dal tipo di porte, dal batch e dal metodo di differenziazione. Non si può quindi attribuire ogni differenza temporale al solo numero di parametri addestrabili.

In questa tesi le operazioni quantistiche sono simulate e i valori attesi sono calcolati senza shot finiti. Non si modellano rumore del dispositivo, errori di lettura o vincoli di accesso a una QPU. L'esperimento studia il comportamento predittivo delle architetture e il costo della loro implementazione simulata, non un'accelerazione ottenuta su hardware quantistico.

2.5 Potenzialità, limiti e criteri di confronto

2.5.1 Espressività, generalizzazione e ottimizzazione

L'*espressività* riguarda le funzioni rappresentabili da un modello; la *generalizzazione* riguarda le prestazioni su esempi non usati per addestrarlo. Una famiglia più ampia non garantisce una generalizzazione migliore: contano dati disponibili, regolarizzazione e procedura di ottimizzazione. Anche un numero ridotto di pesi non implica automaticamente un vantaggio nei regimi con pochi esempi.

Per i circuiti quantistici, McClean et al. [16] mostrano che determinate famiglie di circuiti e condizioni di inizializzazione possono produrre gradienti la cui varianza si riduce esponenzialmente con il numero di qubit. Queste regioni del paesaggio di ottimizzazione sono dette *barren plateau*. Il fenomeno costituisce un limite teorico importante, ma non è una spiegazione automatica di ogni risultato negativo. Non è sufficiente osservare una Macro-F1 bassa per diagnosticarlo, soprattutto in circuiti piccoli e poco profondi: servono analisi specifiche dei gradienti e delle condizioni teoriche.

2.5.2 Baseline, ablazioni e significato del vantaggio

Un modello ibrido deve essere confrontato con controlli che permettano di distinguere l'effetto del circuito da quello di altre scelte. Una baseline lineare descrive quanto le classi siano linearmente separabili nello spazio delle feature; una testa non lineare offre un riferimento più flessibile; un bottleneck classico della stessa dimensione controlla la compressione. Un'ablazione con circuito congelato verifica invece il contributo dell'addestramento dei parametri quantistici.

Capacità comparabile non significa equivalenza delle famiglie funzionali. Condividere dimensioni e inizializzazioni di alcuni strati riduce le differenze non pertinenti alla domanda di ricerca, ma non rende i modelli identici per espressività o ottimizzabilità. Bowles et al. [3] sottolineano l'importanza delle baseline e del disegno sperimentale nel valutare modelli di quantum machine learning, mostrando quanto sia limitante una lettura basata sulla sola graduatoria delle prestazioni.

Un *vantaggio predittivo* richiede un miglioramento valutato su dati non usati per selezionare il modello e rispetto a riferimenti adeguati. Un *vantaggio computazionale* riguarda invece risorse e costi necessari per ottenere un risultato comparabile. Le due nozioni non coincidono. Per questo la tesi considera congiuntamente classificazione, qualità delle probabilità e tempi, con le metriche e gli indicatori statistici definiti nel Capitolo 4. La prestazione di un singolo seed non è sufficiente a caratterizzare un'architettura.

2.6 Lavori correlati e posizionamento della tesi

2.6.1 Dalla classificazione visuale alle reti profonde

Galaxy Zoo raccoglie le classificazioni visuali espresse da più volontari sulle stesse immagini di galassie. I giudizi vengono combinati in frazioni di voto relative alle categorie morfologiche, come ellittica, spirale e sistema in interazione o fusione [13]. Queste informazioni permettono di costruire dataset etichettati per addestrare e

valutare classificatori automatici. Nella presente tesi, le etichette sono assegnate applicando le soglie e i criteri descritti nel capitolo 3. Dieleman et al. [6] mostrano come reti convoluzionali progettate tenendo conto delle rotazioni possano apprendere la classificazione morfologica dalle annotazioni. Il loro problema di predizione e la struttura delle etichette non coincidono però con le tre classi operative della presente tesi: i punteggi non costituiscono un confronto numerico diretto con i nostri risultati.

In questo lavoro il backbone preaddestrato rimane fisso. L'analisi si concentra sulla testa e sulla trasformazione applicata alle feature compresse, mantenendo comune la rappresentazione fornita ai modelli.

2.6.2 Transfer learning classico-quantistico

Mari et al. [15] costituiscono il riferimento architetturale per combinare un estrattore classico preaddestrato con un circuito variazionale e strati classici di interfaccia. L'obbiettivo è rendere utilizzabili piccoli registri quantistici su rappresentazioni di immagini ad alta dimensionalità. Questa fattibilità non implica, da sola, che il circuito superi una testa classica ben controllata.

Otgonbaatar et al. [20] studiano il transfer learning quantistico su dataset reali di telerilevamento, anche piccoli e ad alta dimensionalità. Il contesto motiva l'attenzione alla scarsità di dati, ma non consente di trasferire direttamente conclusioni al dominio galattico. Differiscono caratteristiche delle immagini, etichette e configurazioni circuitali.

Kim et al. [12] considerano invece il trasferimento verso reti convoluzionali quantistiche. È importante distinguere questa impostazione dalla nostra: nel presente studio convoluzioni ed estrazione spaziale rimangono classiche; il circuito interviene soltanto sul vettore di feature compresso.

2.6.3 Contributo sperimentale del lavoro

Il lavoro si colloca tra queste proposte architetturali e l'esigenza di una valutazione controllata. Lo studio di Bowles et al. [3] offre un riferimento metodologico per interrogare il ruolo effettivo delle componenti quantistiche.

La tesi studia una rappresentazione classica comune, controlli con bottleneck di pari dimensione e circuiti sia addestrabili sia congelati. Il confronto è ripetuto su due task e su quattro regimi di disponibilità dei dati di training, distinguendo i confronti principali Q–B2 dalle analisi esplorative.

Queste ultime comprendono il confronto tra circuito addestrabile e congelato (Q–QF), l'effetto del passaggio da quattro a otto qubit, le prestazioni sulla classe merger e la variazione del divario classico–quantistico tra il task binario e quello a tre classi. Sono inoltre esaminate la calibrazione delle probabilità predette e la relazione tra prestazioni e costo computazionale. Queste analisi approfondiscono il comportamento dei modelli, privilegiando le dimensioni degli effetti e gli intervalli di incertezza rispetto alla formulazione di ulteriori conclusioni confermative.

L'obiettivo non è assumere un vantaggio quantistico, ma individuare se e in quali condizioni il circuito apporti un beneficio rispetto alle alternative classiche e a quale costo. I capitoli successivi traducono questa domanda in un dataset verificabile e in un protocollo sperimentale riproducibile

Capitolo 3

Dataset e protocollo di validazione

Per confrontare i classificatori classici e ibridi, i modelli devono essere valutati sugli stessi esempi. Questo Capitolo descrive la costruzione del dataset, dalla selezione del catalogo alle partizioni di training, validation e test. Sono riportati i controlli usati per garantire l'appaiamento e i limiti del campione selezionato.

Il dataset finale comprende 5 628 immagini, suddivise in tre classi bilanciate: galassie ellittiche, galassie spirali e sistemi classificati come *merger*. A partire da questo insieme si definiscono un problema binario, limitato alle ellittiche e alle spirali, e un problema a tre classi, che include anche i merger. L'introduzione di questi ultimi consente di valutare i modelli in uno scenario di maggiore complessità morfologica, verificando se le differenze tra classificatori classici e quantistici emergano più chiaramente rispetto al caso binario. La valutazione si basa su dieci ripetizioni di un holdout stratificato. Per ciascuna ripetizione vengono costruiti sottoinsiemi stratificati del training set, al fine di analizzare l'impatto della disponibilità dei dati.

3.1 Provenienza dei dati e popolazione selezionata

Le immagini e i metadati provengono dai servizi dello Sloan Digital Sky Survey (SDSS), utilizzati attraverso la Data Release 17 (DR17) [1]. Le informazioni morfologiche sono quelle di Galaxy Zoo presenti nel database `zooSpec`[1]: il servizio di accesso è DR17, ma ciò non implica che le classificazioni morfologiche siano state prodotte originariamente per questa release. Galaxy Zoo raccoglie classificazioni visuali collaborative, successivamente sintetizzate in frazioni di voto e indicatori morfologici [13].

L'estrazione del catalogo è stata effettuata mediante una query CasJobs che collega `PhotoObj`, `zooSpec` e `SpecObj`. Sono richiesti il flag fotometrico `clean=1`, la classificazione `type=3`, una magnitudine nella banda g compresa tra 14 e 17,5 e un redshift compreso tra 0,005 e 0,1. La query, riportata nell' Appendice A, usa l'operatore `BETWEEN`, che include gli estremi; il successivo controllo locale sul redshift applica invece $0{,}005 < z < 0{,}1$.

Il file esportato conserva identificativo dell'oggetto, ascensione retta, declinazione, redshift e tre indicatori morfologici. Non conserva invece le colonne `clean`, `type`

[1]Schema e dati su SDSS DR17 SkyServer e CasJobs. La tabella integra i dati spettroscopici SDSS con le frazioni di voto di Galaxy Zoo 1 (probabilità per ellittiche, spirali e merger). Si interroga via SQL (cfr. Capitolo A) tramite il tool web *SQL Search* o tramite account CasJobs, con export dei risultati da `mydb` in CSV.

Classe	Indicatore nel catalogo	Condizione
Ellittica	`p_el_debiased`	$p_{\mathrm{E}} > 0{,}8$
Merger	`p_mg`	$p_{\mathrm{M}} > 0{,}4$
Spirale	`p_cs_debiased`	$p_{\mathrm{S}} > 0{,}8$

Tabella 3.1: Regole di etichettatura. Le disuguaglianze sono strette; deve essere soddisfatta esattamente una delle tre condizioni.

e g. I relativi vincoli sono quindi documentati dalla query di estrazione, ma non possono essere verificati nuovamente a partire dal solo CSV locale. Questa distinzione separa la provenienza documentata dai controlli effettivamente ripetibili sugli artefatti distribuiti.

La popolazione risultante non costituisce un campione indiscriminato di tutte le galassie SDSS: disponibilità spettroscopica, intervallo di magnitudine, redshift e selezione morfologica ne delimitano il campo di validità. Le prestazioni misurate nella tesi si riferiscono a questa popolazione selezionata.

3.2 Assegnazione delle etichette

Per ellittiche e spirali vengono utilizzati rispettivamente `p_el_debiased` e `p_cs_debiased`; per i merger viene utilizzato `p_mg`. Le prime due quantità includono una correzione dei bias osservativi nella classificazione, mentre l'indicatore merger ha una diversa origine nella struttura dei voti. Non è quindi opportuno interpretare le tre soglie come livelli omogenei di probabilità calibrata o come garanzie di correttezza della singola etichetta. Il ruolo delle classificazioni Galaxy Zoo e dell'indicatore di fusione è discusso nei lavori di rilascio e di selezione dei sistemi interagenti [13, 5].

Le soglie operative sono riportate nella Tabella 3.1, sulla voce Condizione. Indicando con p_c l'indicatore della classe c e con τ_c la soglia corrispondente, un oggetto riceve un'etichetta soltanto se

$$\sum_{c\in\{\mathrm{E,M,S}\}} \mathbf{1}\{p_c > \tau_c\} = 1, \qquad \text{con } \mathrm{E,M,S} \in \{\text{ellittiche, merger, spirali}\}. \tag{3.1}$$

L'etichetta assegnata è quella dell'unica condizione soddisfatta. Un oggetto che non supera alcuna soglia, oppure ne supera più di una, non viene ammesso come esempio etichettato. La query effettua una prima selezione con un'unione logica delle condizioni; il requisito di unicità viene applicato nella costruzione locale del manifest[2].

La Figura 3.1 mostra le distribuzioni degli indicatori utilizzati per assegnare l'etichetta nei candidati selezionati. Le soglie definiscono il problema supervisionato, ma non eliminano il rumore delle etichette. In particolare, la categoria merger è un'etichetta operativa derivata dal catalogo: la procedura non comprende una nuova revisione visuale esperta di ogni sistema. Né il superamento della soglia 0,4

[2]Registro tabellare che fissa l'elenco degli oggetti inclusi, associando l'`objid` all'etichetta per garantire la tracciabilità e la riproducibilità della pipeline.

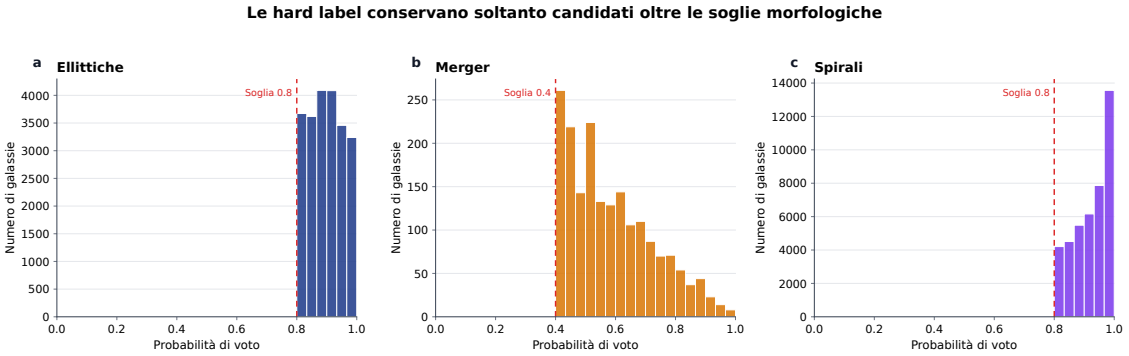


Figura 3.1: Distribuzione degli indicatori morfologici nei candidati selezionati, separati secondo la classe assegnata. Le linee verticali indicano le soglie operative: 0,8 per ellittiche e spirali, 0,4 per merger. Le distribuzioni sono già condizionate dalla selezione e non rappresentano l'intero catalogo sorgente.

riproduce automaticamente tutte le ulteriori selezioni di cataloghi specialistici di fusioni.

3.3 Pulizia, acquisizione e bilanciamento

3.3.1 Integrità del catalogo

Il catalogo esportato contiene 65 906 righe. La pulizia rimuove cinque duplicati esatti e 72 righe associate a 36 identificativi discordanti. Per questi ultimi vengono escluse tutte le occorrenze, anziché scegliere arbitrariamente una delle versioni. Rimangono 65 829 candidati: 22 163 ellittiche, 1 877 merger e 41 789 spirali.

Gli identificativi SDSS `objid` vengono conservati come stringhe. Questa scelta evita gli arrotondamenti che possono essere introdotti dalla conversione in numeri a virgola mobile di identificativi con molte cifre. L'identificativo viene usato come chiave nei manifest, nelle partizioni e nelle predizioni: una sua alterazione comprometterebbe sia la tracciabilità sia i controlli di sovrapposizione.

3.3.2 Pool di acquisizione e controlli sulle immagini

La classe merger, con 1 877 candidati, determina la scala del bilanciamento. Per disporre di una riserva in caso di download non riusciti o immagini non valide, il pool di acquisizione comprende tutti i merger e 2 347 oggetti per ciascuna delle altre due classi:

$$2\,347 = \lceil 1{,}25 \cdot 1\,877 \rceil .$$

Il campionamento utilizza il seed pseudo-casuale 42 fissato a livello di progetto, assicurando la replicabilità dell'estrazione. Il pool contiene complessivamente 6 571 oggetti, senza richiedere il download di tutti i candidati del catalogo.

Per ogni oggetto è stato richiesto al servizio SDSS un ritaglio (*cutout*) JPEG RGB di 320 × 320 pixel, centrato sulle coordinate catalogate, con scala di 0,396 secondi d'arco per pixel. Il lato dell'immagine corrisponde quindi a circa 126,7 secondi d'arco. Si tratta di immagini di visualizzazione a colori, non di un addestramento direttamente sui dati fotometrici grezzi delle singole bande.

Fase	Ellittiche	Merger	Spirali	Totale
Candidati puliti	22 163	1 877	41 789	65 829
Pool acquisito	2 347	1 877	2 347	6 571
Immagini valide	2 347	1 877	2 347	6 571
Dataset finale	1 876	1 876	1 876	5 628

Tabella 3.2: Numerosità nelle principali fasi della costruzione del dataset. Il pool validato coincide con quello acquisito; il passaggio finale riduce il campione per bilanciamento.

La validazione verifica leggibilità e integrità del file, dimensioni, modalità RGB, dimensione minima di 512 byte e variabilità della luminanza. Quest'ultima è calcolata dai canali RGB tramite

$$Y = 0{,}2126R + 0{,}7152G + 0{,}0722B;$$

è richiesta una deviazione standard di almeno 1, sulla scala 0–255, per individuare immagini sostanzialmente uniformi. Tutti i 6 571 cutout del pool superano i controlli.

Viene inoltre calcolata l'impronta SHA-256 dei file per rilevare duplicati identici a livello di byte, sia entro una classe sia tra classi diverse. Nel pool validato non emergono duplicati di questo tipo. Il controllo non equivale tuttavia a una deduplicazione percettiva: due immagini dello stesso sistema con ritagli o codifiche differenti possono avere hash diversi. Analogamente, identificativi distinti non garantiscono che due cutout non includano porzioni di cielo comuni.

3.3.3 Dataset finale

Il numero finale per classe è fissato a 1 876, arrotondando 1 877 al multiplo di quattro inferiore. Questo consente quote stratificate esatte per la successiva ripartizione 50/25/25. Il campionamento finale è deterministico e riproducibile: il generatore pseudo-casuale adotta il seed di progetto (42) traslato di un offset intero distinto per ciascuna classe, disaccoppiando così le sequenze di estrazione ed evitando correlazioni tra le categorie.

La Tabella 3.2 e la Figura 3.2 riepilogano le numerosità. Dei 6 571 file validi, 943 non entrano nel campione finale: 471 ellittiche, un merger e 471 spirali. Queste esclusioni derivano dal bilanciamento e non da un fallimento dei controlli di qualità.

Il cambiamento della composizione di classe è illustrato nella Figura 3.3. Il bilanciamento facilita il confronto tra classi e impedisce che la numerosità molto maggiore delle spirali domini l'addestramento. Modifica però la prevalenza rispetto al catalogo: metriche aggregate e probabilità prodotte dal classificatore non possono essere trasferite automaticamente a una popolazione astronomica con frequenze diverse.

3.4 Caratteristiche del campione e trasformazioni

3.4.1 Redshift e limiti del controllo osservativo

La Figura 3.4 descrive il redshift delle tre classi nel dataset finale. Il bilanciamento numerico non rende identiche le distribuzioni delle altre proprietà: le classi mantengono distribuzioni di redshift differenti. La figura è una descrizione del campione,

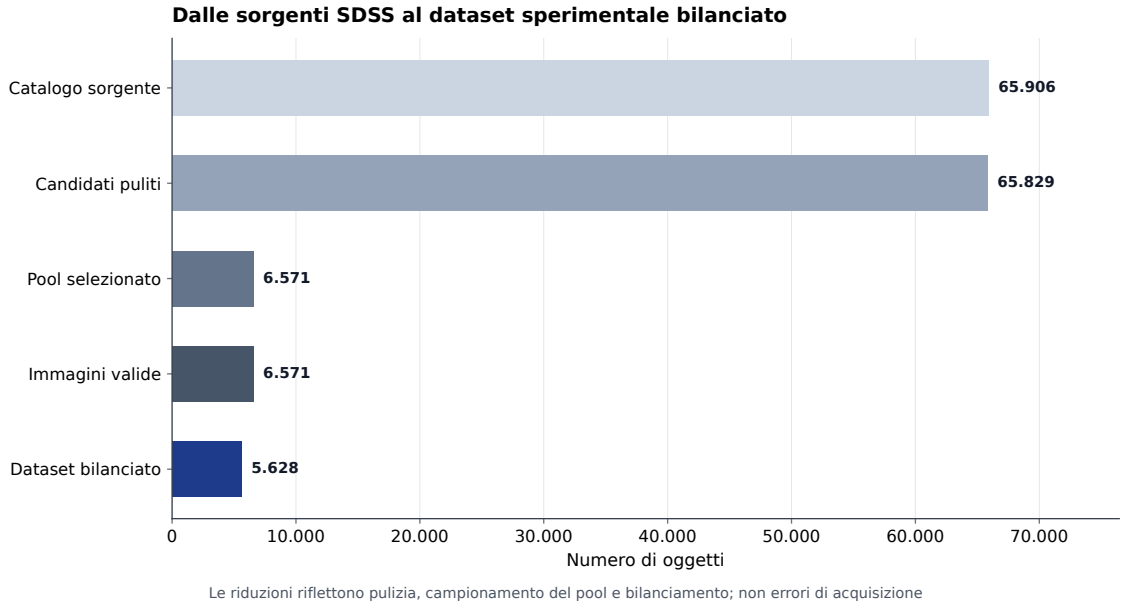


Figura 3.2: Numerosità lungo la pipeline: catalogo esportato, candidati puliti, pool di download, immagini valide e dataset finale. La riduzione tra candidati e pool è una selezione pianificata; quella tra immagini valide e dataset finale dipende dal bilanciamento.

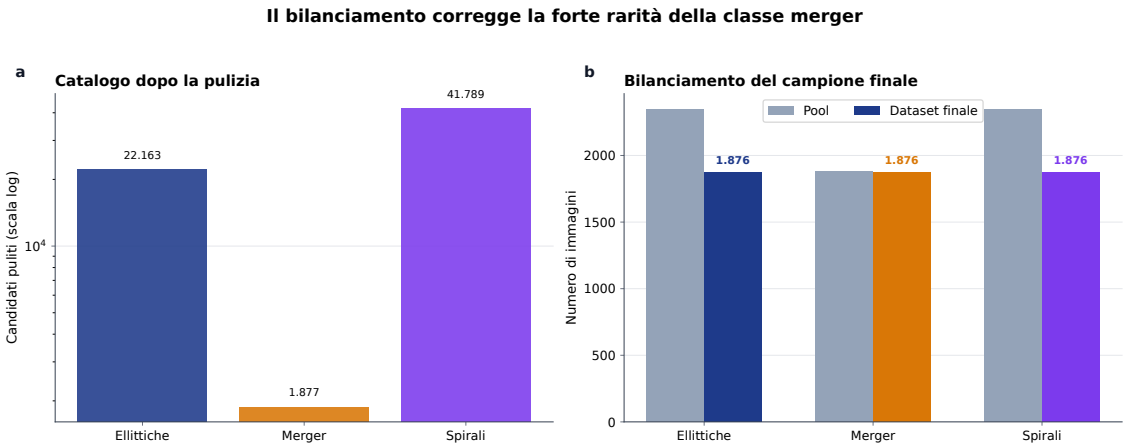


Figura 3.3: Composizione per classe dei candidati, del pool di acquisizione e del dataset finale. Il pannello dei candidati utilizza una scala logaritmica. Il campione finale contiene 1 876 oggetti per classe; questa distribuzione è una scelta sperimentale, non una stima della prevalenza delle morfologie nella popolazione SDSS.

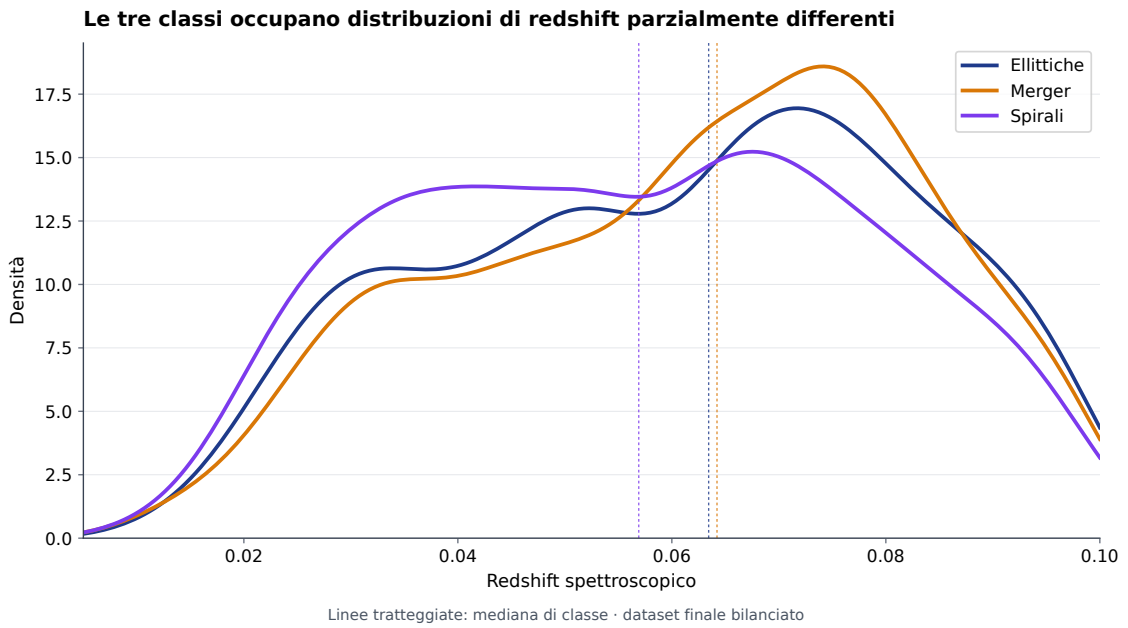


Figura 3.4: Distribuzione del redshift nel dataset finale, distinta per classe. Le curve rappresentano stime di densità; le linee verticali indicano le mediane. La selezione nell'intervallo $0{,}005 < z < 0{,}1$ non comporta un abbinamento delle distribuzioni di redshift tra classi.

non un test di significatività né una dimostrazione che il redshift causi gli errori del classificatore.

Coordinate, redshift e frazioni di voto sono usati per costruzione e audit del dataset, non come input aggiuntivi del classificatore. Ciò non esclude che proprietà correlate a questi metadati, come dimensione apparente o risoluzione delle strutture, siano presenti nelle immagini. Non è stato applicato un abbinamento tra classi per redshift o dimensione angolare. Questo aspetto delimita l'interpretazione astronomica dei risultati.

3.4.2 Preprocessing e rappresentazione condivisa

Nella pipeline di preprocessing, le immagini di training da 320×320 pixel vengono ruotate di un angolo casuale tra $0°$ e $360°$ con interpolazione bilineare, e successivamente ritagliate al centro a 224×224 pixel tramite TorchVision, dimensionandole per l'input atteso dal backbone ResNet-18. Seguono riflessioni orizzontali e verticali casuali, ciascuna con probabilità 0,5. Eseguire il ritaglio dopo la rotazione sfrutta il margine dell'immagine originale: poiché il quadrato privo di artefatti inscrivibile nell'immagine ruotata ha lato pari a $320/\sqrt{2} \simeq 226{,}3$ pixel > 224 pixel, si garantisce che, per qualunque angolo, il ritaglio finale non contenga mai i bordi neri introdotti dalla rotazione.

Le intensità dei pixel dei tre canali RGB (originariamente interi in $[0, 255]$ vengono convertite in tensori a virgola mobile nell'intervallo $[0, 1]$ e normalizzate per canale con medie $0{,}485, 0{,}456, 0{,}406$ e deviazioni standard $0{,}229, 0{,}224, 0{,}225$, coerentemente con i requisiti del pre-addestramento su ImageNet. Validation e test impiegano soltanto ritaglio centrale, conversione e normalizzazione, senza trasformazioni casuali.

Task	Training	Validation	Test	Totale
Binario	1 876	938	938	3 752
Tre classi	2 814	1 407	1 407	5 628
Per classe	938	469	469	1 876

Tabella 3.3: Numerosità per ciascuna ripetizione del protocollo. Nella riga per classe i conteggi valgono per ciascuna classe presente nel task. La denominazione *Full* indica la colonna Training.

Le immagini così trasformate sono elaborate da una ResNet18 [10] con pesi `IMAGENET1K_V1` di TorchVision [25]. Il classificatore finale viene rimosso e ogni immagine è rappresentata da un vettore di 512 feature. Il backbone risultante è congelato e utilizzato in modalità di valutazione: l'esperimento confronta pertanto classificatori che ricevono una rappresentazione classica condivisa, non backbone addestrati separatamente.

Le feature sono precalcolate e conservate in una cache per ripetizione. Nella procedura utilizzata, l'augmentation del training produce una vista per oggetto al momento della costruzione della cache: tale vista rimane fissa nelle epoche successive. Non si tratta quindi di una nuova rotazione a ogni epoca. La condivisione della cache mantiene costante anche questa componente del confronto tra modelli. Il dettaglio delle teste classiche e quantistiche è rinviato al Capitolo 4.

3.5 Task e repeated holdout stratificato

Il task a tre classi utilizza tutte le immagini del dataset finale. Il task binario considera soltanto ellittiche e spirali, escludendo i merger e rimappando le etichette a due classi. Le partizioni binarie derivano dal filtraggio delle corrispondenti partizioni a tre classi: gli oggetti delle due classi comuni mantengono dunque il proprio ruolo di training, validation o test nella stessa ripetizione.

Per ciascun repeat seed il campione viene suddiviso in tre insiemi disgiunti: 50% per l'addestramento, 25% per la validazione e 25% per il test. La stratificazione preserva il bilanciamento tra classi in ogni insieme. Le numerosità sono riportate nella Tabella 3.3.

I dieci repeat seed utilizzati sono

$$42,\ 314,\ 2718,\ 1618,\ 2026,\ 7,\ 73,\ 137,\ 1729,\ 4096.$$

Ogni seed definisce una ripetizione riproducibile. Tutti i modelli condividono le stesse partizioni all'interno della ripetizione: il confronto delle prestazioni viene così effettuato sugli stessi oggetti di test e con gli stessi dati disponibili per l'apprendimento.

L'implementazione costruisce quattro blocchi stratificati di uguale dimensione, con mescolamento determinato dal seed, e ne assegna due al training, uno alla validation e uno al test. L'esperimento conserva esclusivamente la prima assegnazione, identificata negli artefatti da `iteration=1`. Le altre rotazioni non contribuiscono ai risultati della tesi. Il protocollo effettivamente valutato è quindi un *repeated holdout stratificato*, non una cross-validation completa a quattro fold.

La validation è impiegata per monitorare l'apprendimento e selezionare il checkpoint secondo il criterio definito nel Capitolo 4; il test è riservato alla valutazione del modello selezionato. La separazione tra questi ruoli evita che il test venga usato come criterio operativo di arresto dell'addestramento.

La disgiunzione vale entro ciascuna ripetizione. Tra ripetizioni diverse uno stesso oggetto può invece comparire più volte nel test, oppure cambiare ruolo. I dieci risultati misurano quindi la variabilità del protocollo sul medesimo dataset, non quella di dieci campioni astronomici indipendenti. Questa dipendenza va tenuta presente nell'interpretazione degli intervalli e impedisce di trattare tutte le predizioni concatenate come osservazioni indipendenti.

3.6 Regimi a ridotta disponibilità di dati

Per studiare il comportamento in condizioni *low-resource*, il training set viene ridotto a 100, 300 e 900 immagini complessive. Il numero indica il totale del sottoinsieme, non il numero per classe. Validation e test restano invariati rispetto alla ripetizione *Full*: una variazione delle prestazioni non dipende quindi dalla sostituzione del campione su cui vengono misurate.

La selezione è bilanciata, salvo gli inevitabili arrotondamenti. Nel task binario i tre regimi contengono rispettivamente 50, 150 e 450 immagini per classe; nel task a tre classi, il regime da 100 immagini contiene 33, 33 e 34 esempi, mentre quelli da 300 e 900 ne contengono rispettivamente 100 e 300 per classe.

Per ciascuna combinazione di task e repeat seed, ogni sottoinsieme è selezionato esclusivamente dal training completo:

$$\mathcal{T}_n^{(s)} \subset \mathcal{T}_{\text{full}}^{(s)}, \qquad n \in \{100, 300, 900\}. \tag{3.2}$$

La selezione usa un seed condiviso tra i modelli: un controllo classico e il corrispondente classificatore quantistico non vengono addestrati su campioni estratti separatamente.

La logica di campionamento è implementata nella funzione `select_training_subset` (in `scripts/train.py`); la selezione avviene per identificativo di oggetto e non per singola vista aumentata, garantendo la stratificazione delle classi:

```
    requested = int(subset_size)
    identities = bank.metadata[["objid","label"]].drop_duplicates("objid")
    if requested >= len(identities):
        return bank
    selected, _ = train_test_split(identities,
                    train_size=requested,
                    stratify=identities["label"],
                    random_state=seed
    )
    mask = bank.metadata["objid"].isin(selected["objid"])
    metadata = bank.metadata.loc[mask].reset_index(drop=True).copy()
    features = bank.features[torch.from_numpy(mask.to_numpy())]
    metadata["feature_index"] = range(len(metadata))
```

Nel frammento riportato sono omessi import, gestione del regime Full e costruzione del contenitore di uscita.

Nel notebook di esecuzione dei subset, il seed di selezione è quello `dataloader`, condiviso dalle architetture. Il codice conservato effettua una chiamata separata per ciascuna numerosità: non impone esplicitamente l'inclusione del campione da 100 in quello da 300 e di quest'ultimo in quello da 900. Inoltre, il riepilogo denominato `nested_audit` registra le numerosità, ma non verifica tali inclusioni. Non si assume pertanto un annidamento reciproco dimostrato. Le curve descrivono l'effetto del regime di campionamento; le differenze possono dipendere anche dalla composizione del sottoinsieme, oltre che dalla numerosità e dalla variabilità dell'ottimizzazione.

Il regime *Full* corrisponde a 1 876 immagini di training nel binario e a 2 814 nel task a tre classi. Nei grafici comparativi questa etichetta deve dunque essere distinta da una numerosità universale. Le curve rispetto a 100, 300, 900 e *Full* descrivono l'effetto della quantità di dati, non l'andamento della loss nelle epoche.

3.7 Tracciabilità e perimetro delle conclusioni

La pipeline conserva manifest del catalogo, download, validazione e campione finale, insieme alle assegnazioni dei singoli oggetti alle partizioni. Gli artefatti di ogni run comprendono configurazione, cronologia dell'addestramento, checkpoint, metriche e predizioni. Il collegamento tramite identificativi consente di ricondurre una metrica aggregata agli esempi valutati e di verificare l'appaiamento tra modelli.

Ai fini del confronto sperimentale, i principali controlli sono l'unicità degli identificativi nel campione, la verifica degli hash, la separazione dei ruoli entro ciascun holdout, la condivisione delle feature e l'invarianza di validation e test nei regimi ridotti. Questi controlli non sostituiscono una validazione esterna. Rimangono possibili rumore nelle etichette, differenze osservazionali tra classi e correlazioni tra oggetti astronomicamente vicini; non viene effettuata una suddivisione per gruppi di sistemi fisici o regioni di cielo.

Il protocollo consente pertanto di studiare l'effetto della scelta del classificatore su una rappresentazione e su partizioni controllate. Non misura, da solo, la capacità di generalizzare a survey differenti o a una popolazione con diversa prevalenza morfologica. Su questa base, il capitolo successivo definisce le architetture, le condizioni di addestramento e i confronti statistici con cui vengono valutate le domande di ricerca.

Capitolo 4

Modelli e disegno sperimentale

Il protocollo del Capitolo 3 mantiene controllati gli oggetti utilizzati per addestramento e valutazione. Su questa base, il presente capitolo definisce che cosa viene modificato nel passaggio dal modello classico a quello quantistico e quali condizioni rimangono invariate. La domanda non è se una rete contenente un circuito quantistico possa classificare immagini, ma se quel circuito apporti un beneficio qualitativo (non di efficienza) nel riconoscimento e la classificasione delle immagini rispetto a un controllo classico che attraversa lo stesso collo di bottiglia.

4.1 Impostazione del confronto

4.1.1 Una rappresentazione classica comune

Tutti i modelli ricevono un vettore $\boldsymbol{f} \in \mathbb{R}^{512}$ prodotto dalla stessa ResNet18 [10] congelata, secondo il preprocessing e la procedura di caching già descritti. Non viene effettuato un fine-tuning del backbone sul dataset galattico. I parametri ottimizzati appartengono esclusivamente alla testa di classificazione.

La costruzione dell'estrattore (in `models/classical.py`) sostituisce lo strato lineare finale (`fc`) con l'identità, in modo da restituire il vettore di 512 feature invece delle classi ImageNet (`pretrained=True`, quindi non utilizzato):

```
1     def resnet18_backbone(*, pretrained: bool= True) ->nn.Module:
2         weights = models.ResNet18_Weights.IMAGENET1K_V1
3         backbone = models.resnet18(weights=weights)
4         backbone.fc = nn.Identity()
5         return backbone
```

Durante il caching, `data/features.py` pone l'estrattore in modalità `eval()` ed esegue l'inferenza entro `torch.no_grad()`. I classificatori finali vengono poi addestrati direttamente sulle feature salvate, escludendo il backbone dal grafo di ottimizzazione.

L'architettura ibrida segue il paradigma del *dressed quantum circuit*: una trasformazione classica prepara l'input del circuito e un'altra ne converte l'uscita nei punteggi di classe. Mari et al. [15] hanno proposto questo schema nell'ambito del transfer learning classico-quantistico. Nel telerilevamento, Otgonbaatar et al. [20] hanno studiato un'impostazione basata su feature classiche e piccoli circuiti, considerando anche varianti con data re-uploading.

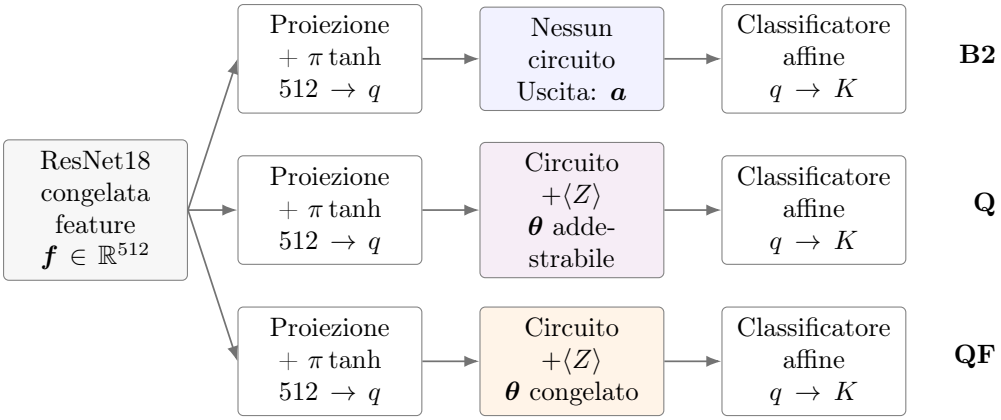


Figura 4.1: Struttura delle teste B2, Q e QF. Le feature $\boldsymbol{f}$ sono condivise. Proiezione e classificatore hanno la stessa forma e gli stessi valori iniziali nelle tre configurazioni appaiate; durante il training vengono ottimizzati separatamente. In QF rimane fisso soltanto il tensore $\boldsymbol{\theta}$ del circuito.

Questi lavori motivano il tipo diarchitettura, non garantiscono un miglioramento nel diverso problema affrontato qui.

Il modello della tesi non applica convoluzioni quantistiche ai pixel e non include operazioni di pooling quantistico. È quindi distinto dalle QCNN con strati di convoluzione e pooling, come quelle considerate da Kim et al. [12]: la parte convoluzionale rimane interamente classica.

4.1.2 Ruolo delle famiglie di modelli

Le baseline B0 e B1 forniscono due riferimenti contestuali: una testa lineare e un percettrone multistrato. Il confronto centrale riguarda invece B2, Q e QF:

B2 è una testa classica con bottleneck di quattro o otto componenti; Q inserisce, dopo la stessa compressione, un circuito variazionale addestrabile; QF mantiene identico il circuito, ma ne congela i parametri interni.

Questa separazione permette di distinguere tre domande. B0 e B1 indicano quanto le feature siano sfruttabili da classificatori classici. Il confronto Q–B2 valuta l'inserimento del circuito a parità di dimensione del bottleneck. Il confronto Q–QF studia il contributo dell'ottimizzazione dei pesi circuitali, rispetto a una trasformazione quantistica fissata all'inizializzazione. La Figura 4.1 riassume la struttura del confronto principale.

4.2 Teste classiche

Si indica con $K \in \{2, 3\}$ il numero di classi e con $\boldsymbol{\ell} \in \mathbb{R}^K$ il vettore dei *logit*, ossia i punteggi non normalizzati prodotti dalla rete. Le probabilità sono ottenute mediante

$$p_k = \frac{\exp(\ell_k)}{\sum_{c=1}^{K} \exp(\ell_c)}, \qquad \widehat{y} = \arg\max_k p_k. \tag{4.1}$$

Anche nel caso binario vengono prodotti due logit e utilizzata la softmax.

4.2.1 B0: classificatore lineare

La baseline B0 applica una trasformazione affine direttamente alle feature:

$$\boldsymbol{\ell}_{\mathrm{B0}} = W_0 \boldsymbol{f} + \boldsymbol{b}_0, \qquad W_0 \in \mathbb{R}^{K\times 512}. \tag{4.2}$$

Il modello verifica quanto il problema sia separabile linearmente nella rappresentazione preaddestrata. La sua semplicità riguarda la testa: l'intera pipeline comprende comunque un backbone convoluzionale profondo.

4.2.2 B1: percettrone multistrato

B1 introduce uno strato nascosto di 512 unità con attivazione ReLU e dropout di probabilità 0,3:

$$\boldsymbol{\ell}_{\mathrm{B1}} = W_2\, D_{0,3}(\mathrm{ReLU}(W_1 \boldsymbol{f} + \boldsymbol{b}_1)) + \boldsymbol{b}_2. \tag{4.3}$$

Il dropout è attivo durante l'addestramento e disattivato in valutazione. B1 non impone la compressione a quattro o otto componenti e dispone di molti più parametri delle teste del confronto centrale. Per questo costituisce un riferimento di contesto, non un controllo a capacità comparabile del circuito.

4.2.3 B2: controllo con bottleneck condiviso

Per $q \in \{4, 8\}$, B2 calcola

$$\boldsymbol{a} = \pi \tanh(W_{\mathrm{in}} \boldsymbol{f} + \boldsymbol{b}_{\mathrm{in}}), \tag{4.4}$$

$$\boldsymbol{\ell}_{\mathrm{B2}} = W_{\mathrm{out}} \boldsymbol{a} + \boldsymbol{b}_{\mathrm{out}}, \tag{4.5}$$

dove $W_{\mathrm{in}} \in \mathbb{R}^{q\times 512}$ e $W_{\mathrm{out}} \in \mathbb{R}^{K\times q}$. La tangente iperbolica agisce componente per componente e limita l'input del blocco successivo all'intervallo $(-\pi, \pi)$.

In B2, q indica esclusivamente una dimensione classica: il modello non contiene qubit. La corrispondenza con Q e QF riguarda la dimensione, la trasformazione di compressione e la struttura del classificatore. Il controllo non sostituisce il circuito con una rete classica arbitraria di dimensione maggiore.

4.3 Classificatore ibrido e circuito variazionale

4.3.1 Encoding delle feature compresse

Q e QF utilizzano la stessa trasformazione della Equazione (4.4). L'input quantistico è quindi il vettore $\boldsymbol{a} \in (-\pi, \pi)^q$, non il vettore originale di 512 feature né l'immagine. I qubit sono inizializzati in $|0\rangle^{\otimes q}$. La codifica applica una rotazione $R_Y(a_j)$ al qubit j:

$$U_{\mathrm{enc}}(\boldsymbol{a}) = \bigotimes_{j=0}^{q-1} R_Y(a_j), \qquad R_Y(a) = \begin{pmatrix} \cos(a/2) & -\sin(a/2) \\ \sin(a/2) & \cos(a/2) \end{pmatrix}. \tag{4.6}$$

Prima dell'entanglement lo stato è un prodotto:

$$U_{\mathrm{enc}}(\boldsymbol{a})|0\rangle^{\otimes q} = \bigotimes_{j=0}^{q-1} \left[\cos(a_j/2)|0\rangle + \sin(a_j/2)|1\rangle\right].$$

Ogni componente compressa determina dunque una rotazione locale. La compressione è appresa dalla rete e non coincide con una selezione manuale di quattro o otto descrittori astronomici.

4.3.2 Ansatz e ordine delle operazioni

Il circuito utilizzato dagli esperimenti è stato progettato e implementato nell'ambito di questa tesi. Esso non coincide con un circuito predefinito della libreria PennyLane né con l'implementazione specifica di uno degli articoli citati. La letteratura fornisce il paradigma generale del classificatore ibrido e dei circuiti variazionali, mentre la scelta concreta dell'ansatz è stata effettuata per ottenere un circuito compatto, riproducibile e confrontabile nelle configurazioni a quattro e otto qubit. La profondità del circuito e il numero di qubit sono stati fissati prima dell'esecuzione della matrice principale. La scelta di $L = 2$ costituisce un compromesso progettuale tra espressività del circuito e costo della simulazione. Con due blocchi, ogni qubit riceve due rotazioni parametrizzate per layer e interagisce con i qubit adiacenti attraverso una catena di CNOT, mantenendo al tempo stesso un numero limitato di parametri. Non è stata eseguita una ricerca sistematica della profondità ottimale; pertanto $L = 2$ non viene presentato come valore universalmente ottimale, ma come configurazione fissata per il confronto controllato.

Sono state considerate due dimensioni del registro, $q = 4$ e $q = 8$, per studiare l'effetto dell'aumento della dimensione del bottleneck quantistico e separarlo dall'effetto della sola presenza del circuito. Il passaggio da quattro a otto qubit raddoppia il numero di componenti codificate e dei parametri circuitali, ma aumenta anche il costo della simulazione. Con $L = 2$, il tensore dei parametri contiene $2Lq$ valori: 16 per quattro qubit e 32 per otto qubit. Il numero di porte CNOT per circuito è invece $L(q-1)$, pari rispettivamente a 6 e 14. Queste due configurazioni permettono quindi un confronto tra un collo di bottiglia più compatto e uno più ampio, senza introdurre una griglia eccessivamente estesa di profondità e dimensioni.

Il circuito impiega $L = 2$ blocchi variazionali. In ciascun blocco, su ogni qubit si applicano prima $R_Z(\theta_{\ell j0})$ e poi $R_Y(\theta_{\ell j1})$. Segue una catena di CNOT nelle direzioni

$$0 \longrightarrow 1, \quad 1 \longrightarrow 2, \quad \ldots, \quad q-2 \longrightarrow q-1,$$

eseguite nell'ordine indicato. Non è presente una CNOT di chiusura dall'ultimo al primo qubit.

Per rendere esplicito l'ordine matriciale, si definiscono

$$V_\ell(\boldsymbol{\theta}_\ell) = \bigotimes_{j=0}^{q-1} R_Y(\theta_{\ell j1}) R_Z(\theta_{\ell j0}), \tag{4.7}$$

$$E = \mathrm{CNOT}_{q-2,q-1} \cdots \mathrm{CNOT}_{1,2} \mathrm{CNOT}_{0,1}. \tag{4.8}$$

Gli operatori a destra agiscono per primi. Lo stato finale è

$$|\psi(\boldsymbol{a}, \boldsymbol{\theta})\rangle = E V_2(\boldsymbol{\theta}_2)\, E V_1(\boldsymbol{\theta}_1)\, U_{\mathrm{enc}}(\boldsymbol{a}) |0\rangle^{\otimes q}. \tag{4.9}$$

La Figura 4.2 mostra il blocco per quattro qubit. L'encoding compare una sola volta: aumentare il numero di blocchi variazionali non significa reintrodurre i dati a ogni blocco. Il circuito primario non utilizza quindi data re-uploading, amplitude encoding o il template `BasicEntanglerLayers`.

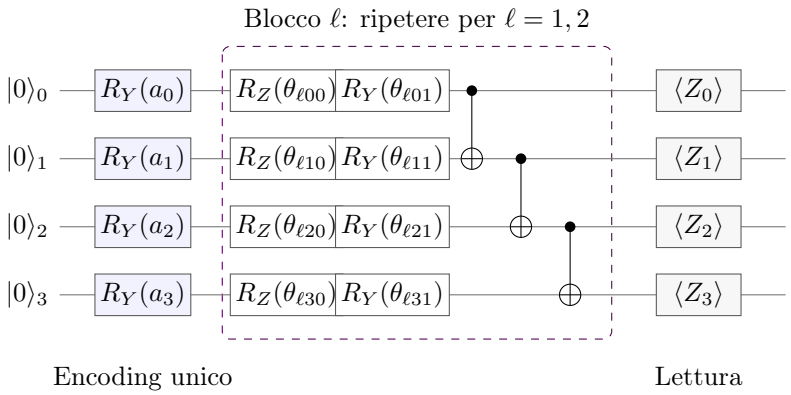


Figura 4.2: Circuito a quattro qubit. L'encoding $R_Y(a_j)$ viene eseguito una volta; il riquadro tratteggiato viene ripetuto due volte, con parametri diversi nei due blocchi. Le CNOT formano una catena aperta nell'ordine da sinistra a destra. L'uscita comprende i quattro valori attesi locali di Pauli-Z.

Il tensore variazionale ha forma $L \times q \times 2$, per un totale di $2Lq$ parametri: 16 con quattro qubit e 32 con otto. Il numero di CNOT è $L(q-1)$, rispettivamente 6 e 14. La dimensione dello spazio di Hilbert passa da $2^4 = 16$ a $2^8 = 256$, ma questi numeri non indicano né il numero di immagini memorizzabili né il numero di feature classiche indipendenti fornite all'encoding. La crescita dello spazio degli stati non costituisce, da sola, una garanzia di capacità utile o di generalizzazione.

4.3.3 Lettura e classificazione

Dal circuito vengono estratti i valori calcolati dal simulatore

$$z_j = \langle \psi(\boldsymbol{a}, \boldsymbol{\theta}) | Z_j | \psi(\boldsymbol{a}, \boldsymbol{\theta}) \rangle, \qquad j = 0, \ldots, q-1. \tag{4.10}$$

Il vettore $\boldsymbol{z} \in [-1, 1]^q$ alimenta un classificatore affine:

$$\boldsymbol{\ell}_{\mathrm{Q}} = W_{\mathrm{out}} \boldsymbol{z} + \boldsymbol{b}_{\mathrm{out}}.$$

Le probabilità di classe derivano dalla softmax, non direttamente dalla misura di un singolo qubit. In particolare, gli otto qubit della variante più grande non corrispondono a otto classi.

4.3.4 QF: circuito congelato, rete ancora addestrabile

QF ha la stessa espressione di Q, ma il tensore $\boldsymbol{\theta}$ resta fisso ai valori iniziali. Proiezione $W_{\mathrm{in}}, \boldsymbol{b}_{\mathrm{in}}$ e classificatore $W_{\mathrm{out}}, \boldsymbol{b}_{\mathrm{out}}$ rimangono addestrabili. Il circuito continua quindi a elaborare input che cambiano durante l'ottimizzazione.

Congelare i pesi non interrompe il gradiente rispetto agli angoli. La regola della catena contiene infatti il contributo

$$\frac{\partial \mathcal{L}}{\partial W_{\mathrm{in}}} = \frac{\partial \mathcal{L}}{\partial \boldsymbol{z}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{a}} \frac{\partial \boldsymbol{a}}{\partial W_{\mathrm{in}}},$$

che deve essere calcolato anche in QF. Non è pertanto corretto attendersi che il costo del circuito congelato scompaia. L'implementazione esclude i pesi quantistici dall'ottimizzatore e ne controlla il checksum durante il training.

Il confronto Q–QF valuta il beneficio dell'ottimizzazione circuitale all'interno di questo sistema congiunto. Non isola invece l'effetto dell'entanglement: entrambi i modelli contengono le stesse CNOT.

4.3.5 Passaggi essenziali dell'implementazione

I frammenti seguenti, estratti dai moduli `models/classical.py` e `models/pennylane_qnn.py`, collegano la formulazione teorica al codice effettivamente eseguito.

La proiezione lineare verso le q componenti e il ramo attivo della funzione `scale_angles` (configurato con `tanh_pi`) convertono le feature in angoli compresi nell'intervallo $[-\pi, \pi]$:

```
    self.pre_quantum = nn.Linear(input_dim, n_qubits)

    if mode == "tanh_pi":
        return torch.tanh(values) * math.pi
```

Nel modello di controllo classico B2, il vettore latente compresso viene impiegato direttamente dallo strato di classificazione:

```
    def forward(self, features: torch.Tensor) -> torch.Tensor:
        latent = scale_angles(
            self.pre_head(features), self.angle_scale
        )
        return self.classifier(latent)
```

Nelle architetture ibride Q e QF, invece, la medesima proiezione alimenta il circuito quantistico variazionale:

```
    def forward(self, features: torch.Tensor) -> torch.Tensor:
        angles = scale_angles(
            self.pre_quantum(features), self.angle_scale
        )
        quantum_features = self.quantum_layer(angles).to(
            dtype=features.dtype
        )
        return self.post_quantum(quantum_features)
```

Il circuito quantistico è implementato mediante un QNode PennyLane (con differenziazione `backprop`, due strati variazionali e porte CNOT tra coppie di qubit adiacenti):

```
    @qml.qnode(device, interface="torch", diff_method=diff_method)
    def circuit(inputs, weights):
        for wire in range(spec.n_qubits):
            qml.RY(inputs[..., wire], wires=wire)
        for layer in range(spec.n_layers):
            for wire in range(spec.n_qubits):
                qml.RZ(weights[layer, wire, 0], wires=wire)
                qml.RY(weights[layer, wire, 1], wires=wire)
```

Configurazione	Binario ($K = 2$)	Tre classi ($K = 3$)
B0	1 026/1 026	1 539/1 539
B1	263 682/263 682	264 195/264 195
B2–4	2 062/2 062	2 067/2 067
B2–8	4 122/4 122	4 131/4 131
Q–4	2 078/2 078	2 083/2 083
Q–8	4 154/4 154	4 163/4 163
QF–4	2 078/2 062	2 083/2 067
QF–8	4 154/4 122	4 163/4 131

Tabella 4.1: Parametri delle teste di classificazione. Ogni cella riporta totali/addestrabili; in QF la differenza corrisponde ai pesi circuitali congelati. Il backbone non è incluso.

```
            for control, target in spec.entangling_pairs:
                qml.CNOT(wires=[control, target])
        return [
            qml.expval(qml.PauliZ(wire))
            for wire in range(spec.n_qubits)
        ]
```

L'encoding iniziale è esterno al ciclo degli strati, la misurazione produce un valore atteso per ciascun qubit, successivamente convertito nei logit di classe dal livello `post_quantum`.

Infine, il controllo con circuito congelato (QF) è implementato disattivando il gradiente esclusivamente sui pesi variazionali del circuito (`quantum_frozen=True`):

```
    self.quantum_weight().requires_grad_(not self.quantum_frozen)
```

Il metodo `quantum_weight()` restituisce il tensore `self.quantum_layer.weights`. In QF i pesi circuitali rimangono bloccati ai valori casuali iniziali, mentre i livelli classici continuano a essere addestrati. Il forward del circuito non viene racchiuso in `torch.no_grad()`, preservando così il flusso del gradiente necessario ad aggiornare lo strato classico di proiezione iniziale.

4.4 Numero di parametri e controlli di appaiamento

4.4.1 Capacità comparabile, non equivalenza architetturale

I parametri delle due trasformazioni affini condivise sono

$$P_{\mathrm{cl}}(q, K) = (512 + 1)q + (q + 1)K. \tag{4.11}$$

B2 ottimizza P_{cl} parametri; Q ne ottimizza $P_{\mathrm{cl}} + 2Lq$. QF conserva lo stesso numero totale di parametri di Q, ma ne ottimizza soltanto P_{cl}. I conteggi nella Tabella 4.1, verificati rispetto alle metriche delle run, escludono il backbone congelato condiviso.

La maggior parte dei parametri delle teste ibride appartiene dunque agli strati classici. L'espressione *capacity-matched* viene utilizzata in senso operativo: stessa dimensione di compressione, stesse interfacce affini e numero di parametri vicino. Non implica uguaglianza delle classi di funzioni realizzabili, della geometria dell'ottimizzazione o della capacità statistica.

Inoltre, passare da quattro a otto qubit modifica anche le dimensioni degli strati classici. Il confronto $8-4$ non misura quindi un effetto del solo registro quantistico a parità di tutti gli altri parametri. B2 nelle due dimensioni fornisce il riferimento per interpretare questa variazione.

4.4.2 Inizializzazione e sorgenti di casualità

Per ciascun task, repeat seed e dimensione q, B2, Q e QF iniziano con gli stessi pesi e bias della proiezione e del classificatore. Le componenti di uno strato affine con d ingressi sono estratte uniformemente in $[-1/\sqrt{d}, 1/\sqrt{d}]$. Q e QF condividono anche i pesi circuitali iniziali, estratti da

$$\theta_{\ell jr} \sim \mathcal{N}(0, 0{,}05^2).$$

Dopo l'inizializzazione, le reti vengono addestrate separatamente: l'appaiamento non impone che i pesi classici restino uguali.

Il repeat seed determina sotto-seed distinti per vista delle feature, inizializzazione condivisa, inizializzazione quantistica, ordine del DataLoader e librerie. L'ordine degli esempi è condiviso tra B2, Q e QF; le selezioni dei subset usano lo stesso insieme di oggetti. Negli artefatti finali, i 160 gruppi definiti da task, regime, dimensione e seed presentano metadati coerenti per questi controlli e per i checksum iniziali.

L'inizializzazione a piccoli angoli è una scelta del protocollo, non una dimostrazione di assenza di *barren plateau*. Il fenomeno discusso da McClean et al. [16] riguarda la concentrazione dei gradienti in determinate famiglie di circuiti. Per diagnosticarlo qui servirebbero misure specifiche dei gradienti circuitali e della loro dipendenza dalla dimensione, non la sola presenza di un training concluso.

4.5 Addestramento e selezione del modello

4.5.1 Funzione obiettivo e ottimizzatore

Tutte le teste minimizzano la cross-entropy non pesata:

$$\mathcal{L} = -\frac{1}{B}\sum_{i=1}^{B} \log p_{i,y_i}, \tag{4.12}$$

dove B è il numero di esempi nel minibatch. La funzione `CrossEntropyLoss` riceve direttamente i logit, evitando un'applicazione preventiva della softmax nella funzione di costo.

L'ottimizzatore è AdamW, con learning rate iniziale 10^{-3} e weight decay 10^{-4}. AdamW separa il decadimento dei pesi dall'aggiornamento adattivo dovuto al gradiente [14]; non viene quindi descritto come la semplice aggiunta di una penalizzazione L_2 alla loss. L'implementazione utilizza i valori predefiniti di AdamW per

Impostazione	Valore
Input della testa	512 feature precalcolate per immagine
Batch B2/Q/QF	8
Batch B0/B1	32
Loss	Cross-entropy non pesata
Ottimizzatore	AdamW; learning rate 10^{-3}, weight decay 10^{-4}
Clipping	Norma euclidea massima 1
Epoche massime	80
Early stopping	Validation loss; patience 12, min delta 10^{-4}
Scheduler	ReduceLROnPlateau; fattore 0,5, patience 4
Circuito	$q = 4$ oppure 8; $L = 2$; $\sigma_{\text{init}} = 0{,}05$
Simulazione	`default.qubit`, `shots=None`, backpropagation

Tabella 4.2: Configurazione di addestramento della matrice finale. Il learning rate del backbone previsto nel file generale non è utilizzato, perché il backbone è congelato.

$\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ ed $\epsilon = 10^{-8}$. Il gradiente complessivo viene limitato con clipping della norma euclidea a 1, prima dell'aggiornamento.

B2, Q e QF utilizzano batch da 8 esempi. B0 e B1 impiegano batch da 32: la parità di minibatch riguarda quindi il confronto centrale, non tutte le baseline. La Tabella 4.2 riassume le condizioni comuni, mantenute anche nei subset.

4.5.2 Validation, arresto e checkpoint migliore

Dopo ogni epoca vengono calcolate loss e metriche sulla validation. Lo scheduler riduce il learning rate quando la validation loss non migliora secondo il criterio di plateau. La decisione di arresto anticipato è gestita separatamente: il contatore delle epoche senza miglioramento viene azzerato quando la loss scende di oltre 10^{-4} rispetto al miglior valore riconosciuto dall'early stopping; il training termina quando il contatore raggiunge 12, oppure all'ottantesima epoca.

La selezione di `best.pt` applica invece il criterio del minimo strettamente osservato della validation loss, senza la soglia `min_delta`. Una piccola riduzione può quindi aggiornare il checkpoint migliore senza azzerare il contatore di early stopping. Questo dettaglio distingue il criterio di selezione da quello di arresto.

Prima della valutazione finale viene ripristinato `best.pt`. Il test viene valutato con quel modello; non guida lo scheduler, l'early stopping o la scelta dell'epoca. Il confronto riguarda dunque le prestazioni dei modelli selezionati dalla validation, non necessariamente quelle dell'ultima epoca.

Gli stessi iperparametri rendono il protocollo controllato, ma non garantiscono che ogni architettura raggiunga la propria prestazione ottimale dopo una ricerca dedicata. Analogamente, a parità di epoche, un subset più piccolo produce meno aggiornamenti dell'ottimizzatore. Le curve low-resource descrivono quindi il comportamento sotto questo budget e questa regola di arresto, non sotto un numero fisso di aggiornamenti.

Regime	Task	Configurazioni/task	Seed	Run
Full	2	8	10	160
100	2	8	10	160
300	2	8	10	160
900	2	8	10	160
Totale				640

Tabella 4.3: Matrice delle run finali. Tutte le run utilizzano l'assegnazione `iteration=1` del repeated holdout.

4.5.3 Simulazione e differenziazione

L'integrazione tra circuito e rete usa PennyLane [2] e l'interfaccia PyTorch [21]. Il backend è `default.qubit`, con `shots=None`: i valori attesi sono calcolati sullo stato simulato, senza rumore di campionamento da un numero finito di misure. Non vengono introdotti canali di rumore hardware e non viene eseguito alcun circuito su QPU.

Con questa configurazione il codice seleziona la differenziazione `backprop`. Il gradiente attraversa le operazioni del simulatore e gli strati classici. Il parameter-shift, che permette di ricavare derivate circuitali da valutazioni con parametri traslati [22], costituisce un'alternativa supportata dal codice per altri backend o configurazioni di misura, ma non è il metodo usato nelle run della matrice finale.

4.6 Matrice sperimentale e gerarchia delle analisi

Per ogni task e regime sono presenti le configurazioni B0, B1, B2–4, B2–8, QF–4, QF–8, Q–4 e Q–8, ciascuna su dieci seed. La Tabella 4.3 distingue l'esperimento *Full* dall'estensione low-resource.

La famiglia primaria comprende quattro confronti Q–B2 sul *Full*: due task per due dimensioni. La famiglia secondaria comprende i dodici confronti Q–B2 ottenuti aggiungendo i tre subset. La correzione per confronti multipli viene applicata separatamente alle due famiglie.

Q–QF, sensibilità 8−4, analisi della classe merger, calibrazione e costo hanno finalità esplorativa. Si privilegiano dimensione dell'effetto e intervalli, senza trasformare tutte le combinazioni di modelli in ulteriori test confermativi. Questa gerarchia organizza l'analisi della tesi; non viene presentata come una preregistrazione pubblica di cui non è disponibile documentazione.

4.7 Metriche di valutazione

Le Tabelle 4.4 e 4.5 offrono una guida alla lettura dei risultati. Le metriche predittive descrivono aspetti diversi del modello; gli indicatori inferenziali descrivono invece effetti e incertezza.

Metrica	Significato	Verso
Accuracy	Quota di esempi classificati correttamente sul totale.	↑
Precision	Per una classe: quota di assegnazioni a quella classe che sono corrette.	↑
Recall	Per una classe: quota dei suoi esempi reali riconosciuta dal modello.	↑
F1 per classe	Media armonica di precision e recall della classe.	↑
Macro-F1	Media delle F1 con uguale peso alle classi; metrica principale della tesi.	↑
Balanced accuracy	Media dei recall; coincide con l'accuracy quando i supporti delle classi sono uguali.	↑
Log-loss	Penalità sulle probabilità delle classi vere; cresce per errori molto confidenti.	↓
Brier score	Errore quadratico delle probabilità rispetto alle etichette in forma one-hot.	↓
ECE	Discrepanza aggregata tra confidenza e accuratezza, raggruppando le predizioni per fasce di confidenza.	↓
Tempo di training	Somma dei tempi di epoca registrati; esclude la costruzione della cache di feature.	↓
Tempo di test	Tempo di predizione sull'intero test dalle feature; non latenza end-to-end dalle immagini.	↓

Tabella 4.4: Guida alle metriche e ai costi utilizzati nella valutazione. Le frecce indicano il verso preferibile, a parità delle altre condizioni. L'ECE dipende dal binning; Brier score e log-loss non misurano soltanto la calibrazione.

Indicatore	Interpretazione
Δ Q–B2	Differenza media appaiata di Macro-F1. Positiva favorisce Q, negativa B2; è espressa in punti percentuali.
IC95%	Intervallo bootstrap per la quantità stimata, come media o differenza. Non è l'intervallo che contiene il 95% delle run.
p_{Holm}	P-value corretto per i confronti multipli della famiglia. Non è la probabilità che l'ipotesi nulla sia vera, né misura l'ampiezza dell'effetto.
d_z	Differenza media divisa per la deviazione standard delle differenze appaiate: misura standardizzata dell'effetto.

Tabella 4.5: Indicatori statistici: non sono metriche di classificazione. Gli intervalli sono marginali, mentre Holm corregge i test all'interno delle famiglie definite dal protocollo.

4.7.1 Macro-F1 e metriche per classe

La metrica principale è la Macro-F1. Per la classe c, indicando con TP_c, FP_c e FN_c veri positivi, falsi positivi e falsi negativi,

$$F_{1,c} = \frac{2\mathrm{TP}_c}{2\mathrm{TP}_c + \mathrm{FP}_c + \mathrm{FN}_c}, \qquad F_{1,\mathrm{macro}} = \frac{1}{K}\sum_{c=1}^{K} F_{1,c}. \tag{4.13}$$

Le classi ricevono uguale peso: si usa la media delle F1 per classe, coerentemente con `average='macro'` di scikit-learn [24][19], non la media armonica di precision e recall macro. Vengono inoltre conservate accuracy, balanced accuracy, precision e recall, sia aggregate sia per classe. Per i merger, precision, recall e F1 sono riportate separatamente per distinguere le diverse modalità di errore.

La matrice di confusione normalizzata per riga descrive la distribuzione delle predizioni condizionata alla classe reale. Per il confronto tra architetture, la sintesi viene effettuata a livello di seed, evitando di interpretare la somma dei test parzialmente sovrapposti come un unico campione indipendente.

Le metriche ROC sono calcolate in modalità one-vs-rest. Il campo `pr_auc` degli artefatti è ottenuto con `average_precision_score`: è quindi *average precision*, non l'area trapezoidale generica sotto una curva precision–recall [23]. Il nome del campo va quindi distinto dalla definizione della metrica.

4.7.2 Qualità delle probabilità

La calibrazione riguarda la corrispondenza tra confidenza prevista e frequenza di correttezza, e non coincide con la sola accuratezza [9]. L'analisi conserva log-loss, Brier score ed expected calibration error (ECE).

Brier score [4] e log-loss valutano la distribuzione di probabilità assegnata alle classi, non soltanto la confidenza della decisione finale. Appartengono alla famiglia delle scoring rule proprie [8]; non sono quindi errori di sola calibrazione.

Il Brier score multiclasse viene calcolato come

$$\mathrm{BS} = \frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{K}\left(p_{ic} - \mathbf{1}\{y_i = c\}\right)^2. \tag{4.14}$$

La somma sulle classi non viene ulteriormente divisa per K. L'ECE usa 15 intervalli equidistanti della confidenza massima:

$$\mathrm{ECE} = \sum_{b=1}^{15}\frac{|I_b|}{N}\left|\mathrm{acc}(I_b) - \mathrm{conf}(I_b)\right|.$$

Il risultato dipende dalla discretizzazione e dalla numerosità del campione. Queste metriche sono diagnostiche complementari; non è stato applicato un ricalibratore post-hoc. Nei confronti Q–B2, una differenza positiva di tali errori favorisce B2, diversamente dalla convenzione usata per la Macro-F1.

4.8 Confronti appaiati e incertezza

4.8.1 Unità di analisi e differenza media

Per task, regime e dimensione fissati si definisce, per ciascun seed s,

$$d_s = F^{\mathrm{Q}}_{1,\mathrm{macro},s} - F^{\mathrm{B2}}_{1,\mathrm{macro},s}, \qquad \bar{d} = \frac{1}{10}\sum_{s=1}^{10} d_s. \tag{4.15}$$

Valori positivi favoriscono Q. Le differenze mostrate nei grafici sono $100 d_s$, espresse in punti percentuali: una differenza di 0,01 in Macro-F1 equivale a un punto percentuale, non a un incremento relativo dell'uno per cento.

La ripetizione identificata dal seed costituisce l'unità di ricampionamento. I risultati dei modelli vengono abbinati prima di calcolare differenze e intervalli. La differenza delle medie coincide con la media delle differenze, ma l'incertezza va stimata ricampionando le coppie: trattare le due serie come indipendenti perderebbe la struttura dell'appaiamento.

4.8.2 Bootstrap e intervalli al 95%

L'Appendice B riporta il nucleo implementativo dell'appaiamento e del bootstrap, separando la costruzione delle coppie dal ricampionamento delle differenze.

La procedura bootstrap ricampiona con reinserimento le dieci osservazioni per seed e ricalcola la statistica [7]. Si utilizzano 10 000 ricampionamenti e i quantili 2,5% e 97,5% delle statistiche ricampionate. Per la Macro-F1 e per gli effetti appaiati la statistica è la media; per le sintesi dei rapporti di costo viene usata la mediana.

Gli intervalli dei grafici finali sono bootstrap percentile, non intervalli di predizione per una nuova galassia e non intervalli simultanei corretti per tutti i confronti. Alcuni riepiloghi intermedi del progetto usano intervalli basati sulla distribuzione t: sono distinti da quelli ricalcolati per le figure finali. Anche due intervalli bootstrap dello stesso effetto possono differire leggermente se ottenuti con seed di ricampionamento diversi.

4.8.3 Test sign-flip e correzione di Holm

Per Q–B2 viene utilizzato un test bilaterale sign-flip sulla media delle differenze. Ogni replica genera segni $\varepsilon_s \in \{-1, +1\}$ e calcola

$$T^* = \left| \frac{1}{10}\sum_{s=1}^{10} \varepsilon_s d_s \right|, \qquad T_{\mathrm{obs}} = |\bar{d}|.$$

Con $R = 10\,000$ repliche Monte Carlo, il p-value è

$$p = \frac{1 + \sum_{r=1}^{R} \mathbf{1}\{T^*_r \geq T_{\mathrm{obs}}\}}{R + 1}. \tag{4.16}$$

Con dieci coppie esistono soltanto $2^{10} = 1\,024$ combinazioni distinte di segni: il codice le campiona con ripetizione, non effettua un'enumerazione esatta. Il numero di repliche non aumenta quindi il numero di unità sperimentali.

I p-value sono corretti con la procedura step-down di Holm [11], separatamente per i quattro test primari e i dodici secondari. La soglia adottata è $p_{\text{Holm}} < 0{,}05$. Gli artefatti riportano anche il test di Wilcoxon [26] e la dimensione standardizzata $d_z = \overline{d}/s_d$, dove s_d è la deviazione standard campionaria delle differenze; tali quantità sono complementari, non criteri alternativi tra cui scegliere quello più favorevole.

Come richiamato nel Capitolo 3, le ripetizioni condividono il dataset. Il bootstrap semplice sui seed e il sign-flip non modellano esplicitamente la dipendenza dovuta agli holdout sovrapposti. Il problema di stimare l'incertezza tenendo conto sia del training sia del test è discusso da Nadeau e Bengio [17]; la presente analisi non applica il loro stimatore corretto della varianza. Inoltre il sign-flip richiede un'appropriata simmetria sotto l'ipotesi nulla, non la sola uguaglianza delle medie. Gli intervalli e i p-value vengono pertanto interpretati nel perimetro del protocollo, senza attribuire loro una validità incondizionata sulla popolazione astronomica. Holm tratta la molteplicità dei test, non corregge queste assunzioni dei test di partenza. L'assenza di significatività non dimostra equivalenza tra modelli.

4.8.4 Analisi esplorative tra task e architetture

Per confrontare il passaggio dal binario alle tre classi viene calcolata, entro ciascun seed e a parità di regime e dimensione, la differenza-in-differenze

$$D_s = \left(F^{\text{Q}}_{1,s} - F^{\text{B2}}_{1,s}\right)_{\text{tre}} - \left(F^{\text{Q}}_{1,s} - F^{\text{B2}}_{1,s}\right)_{\text{binario}}. \tag{4.17}$$

Un valore negativo indica che Q perde terreno rispetto a B2 nel task a tre classi. È un contrasto descrittivo appaiato, non una stima causale: cambiano numero di classi, composizione del problema e, nel *Full*, anche numerosità totale del training.

Analogamente vengono costruite le differenze Q–QF e $8-4$, ricampionando i contrasti per seed. Le analisi merger e calibrazione completano la lettura delle prestazioni senza introdurre nuove famiglie di test oltre a quelle primaria e secondaria.

4.9 Costo computazionale e riproducibilità

4.9.1 Che cosa misurano i tempi

Il campo `training_seconds` è la somma dei tempi di epoca registrati nella history. Comprende training, validation e calcolo delle metriche interne all'epoca, ma non la costruzione iniziale della cache di feature, la valutazione finale e il successivo salvataggio dei checkpoint o dell'archivio. Non coincide quindi con il tempo trascorso dall'avvio della sessione Colab alla sua chiusura.

Il tempo di predizione riportato nel Capitolo dei risultati è `test_inference_seconds`: misura la predizione sull'intero test, a partire dalle feature, dopo il ripristino del checkpoint migliore. È distinto da `inference_seconds`, che negli artefatti misura la predizione sulla validation. Le metriche predittive sono quelle di `test_metrics.json`. Questi tempi non misurano una latenza end-to-end dall'immagine, né il solo tempo di esecuzione delle porte quantistiche.

I rapporti di costo vengono calcolati per seed, per esempio $t_{\text{Q},s}/t_{\text{B2},s}$, e poi sintetizzati con la mediana. Il rapporto delle mediane non è, in generale, la stessa quantità. Nella figura prestazioni–costo ogni configurazione è rappresentata invece dalla Macro-F1 media e dal tempo di training mediano.

Componente	Versione
Python	3.13.15
PyTorch / TorchVision	2.8.0 / 0.23.0
PennyLane	0.42.3
NumPy / pandas	2.2.6 / 2.3.3
scikit-learn	1.7.2
CUDA	12.8

Tabella 4.6: Versioni software dichiarate nei metadati delle run finali. Il backend quantistico è `default.qubit`; la versione CUDA si riferisce alla build software, non al dispositivo usato da ogni run.

4.9.2 Ambienti effettivi e comparabilità dei regimi

I confronti temporali sono effettuati entro ciascun regime, nel quale i modelli appaiati condividono il dispositivo di esecuzione. *Full* è stato eseguito su GPU Tesla T4 e i subset su CPU; i tempi tra regimi diversi non sono pertanto interpretati come una misura di scaling a hardware costante. Anche il confronto predittivo tra subset e *Full* non mantiene identico l'ambiente numerico, pur conservando le partizioni e gli iperparametri previsti dal protocollo.

Le versioni riportate dalle run sono sintetizzate nella Tabella 4.6. I tempi rimangono misure empiriche di una simulazione classica in Colab, condizionate anche da carico della macchina, trasferimenti e overhead software: non forniscono una stima dello speed-up ottenibile su hardware quantistico.

4.9.3 Artefatti e limiti delle diagnostiche

Ogni run conserva configurazione, fingerprint, storia delle epoche, checkpoint migliore e ultimo checkpoint, metriche e predizioni. La ripresa controlla l'identità della configurazione e ripristina anche stato dell'ottimizzatore, scheduler e sorgenti di casualità. Questi meccanismi supportano la tracciabilità delle esecuzioni interrotte, ma non rendono intercambiabili ambienti software diversi.

L'audit distingue inoltre il nome di una diagnostica dalla quantità realmente calcolata. Nella versione usata, il filtro della `quantum_gradient_norm` seleziona i parametri il cui nome contiene la parola `quantum`; include quindi anche `pre_quantum` e `post_quantum`. Quel campo non isola i soli angoli variazionali e non viene utilizzato per sostenere conclusioni sull'assenza di barren plateau.

Con queste precisazioni, il disegno sperimentale consente di valutare prestazioni, stabilità e costo relativo delle teste sotto condizioni documentate. Il Capitolo successivo presenta gli effetti osservati; l'attribuzione di eventuali differenze a specifici meccanismi fisici o di ottimizzazione resta invece materia di discussione e di ulteriori esperimenti.

Capitolo 5

Risultati

Questo capitolo presenta i risultati degli esperimenti definiti nei Capitoli 3 e 4. La domanda centrale è se il bottleneck quantistico addestrabile Q migliori le prestazioni, in termini di riconoscimento delle morfologie galattiche, rispetto al controllo classico B2, a parità delle condizioni di confronto descritte nel protocollo. L'analisi considera sia la classificazione binaria sia quella a tre classi e segue la variazione delle prestazioni al crescere delle immagini disponibili per il training.

Si distingue tra prestazioni assolute, confronti appaiati Q–B2 e analisi esplorative. Le prime descrivono il livello raggiunto dai modelli; i secondi costituiscono il confronto statistico principale; le analisi per classe, Q–QF, dimensionalità, calibrazione e costo precisano la natura delle differenze osservate. Le possibili spiegazioni dei risultati e le implicazioni più generali sono riservate al capitolo di discussione.

5.1 Completezza degli esperimenti e convenzioni di lettura

La matrice finale comprende 640 run: 160 sul training completo e 160 per ciascuno dei subset da 100, 300 e 900 immagini. Per ogni regime sono presenti due task, otto configurazioni e dieci repeat seed. Tutte le run risultano completate e dispongono delle metriche di test. L'analisi non esclude seed sulla base del livello di prestazione raggiunto.

Il protocollo è quello di repeated holdout descritto nel Capitolo 3: per ciascun seed si usa la sola iterazione selezionata, identificata negli artefatti da `iteration=1`. Non si riportano risultati di una cross-validation completa su quattro fold. Le dieci ripetizioni condividono il dataset di partenza e non corrispondono a dieci campioni astronomici indipendenti. La lettura dell'incertezza deve tenere conto della variabilità dovuta sia al training sia al test, come evidenziato nella letteratura sul confronto tra algoritmi di apprendimento [17].

Le prestazioni provengono dai file `test_metrics.json`; i checkpoint erano stati selezionati sulla validation. Il controllo dei risultati aggregati rispetto alle singole run ha confermato la coincidenza delle Macro-F1, delle metriche probabilistiche controllate e dei tempi. Il riepilogo contenuto nel pacchetto dei subset include già anche le run *Full*: queste ultime sono contate una sola volta.

Nelle tabelle delle prestazioni assolute viene riportata $100 \times$ Macro-F1, mentre nei grafici resta la scala $[0, 1]$. Le differenze sono espresse in punti percentuali (pp): una differenza di $-0{,}0167$ nella Macro-F1 corrisponde a circa $-1{,}67$ pp, non a una

diminuzione relativa dell'1,67%. La notazione B2-4 o B2-8 indica la dimensione del bottleneck classico, non la presenza di qubit in B2.

Gli effetti sono calcolati sui valori non arrotondati delle run. La sottrazione dei valori già arrotondati nelle tabelle può quindi differire di 0,01 pp dall'effetto riportato.

Le medie e gli intervalli di confidenza al 95% sono calcolati a livello di repeat seed. Salvo indicazione diversa, gli intervalli sono bootstrap percentile con 10 000 ricampionamenti, secondo il principio di ricampionamento di Efron [7]. Le bande delle figure rappresentano l'incertezza sulla media, non l'intera dispersione delle singole run. I p-value riportati sono quelli dei test appaiati archiviati, corretti con Holm [11] separatamente nella famiglia primaria di quattro confronti *Full* e in quella secondaria di dodici confronti sui subset. Gli intervalli rimangono marginali, non simultanei. Restano valide le cautele inferenziali illustrate nel Capitolo 4.

5.2 Prestazioni assolute e numerosità del training

5.2.1 Classificazione binaria

La Tabella 5.1 raccoglie tutte le configurazioni del task binario. Sul *Full* le medie sono comprese tra 96,00 e 96,34: le differenze assolute tra le architetture sono quindi contenute. Anche i riferimenti B0 e B1 raggiungono circa 96,33 e 96,34, senza che sia necessario introdurre un circuito quantistico. Questi valori forniscono il contesto del problema, ma non sostituiscono il confronto controllato Q–B2.

Modello	100	300	900	Full
B0	91,30 [90,55; 92,03]	94,15 [93,41; 94,90]	95,36 [94,86; 95,87]	96,33 [95,90; 96,75]
B1	92,42 [91,39; 93,39]	95,01 [94,51; 95,53]	95,62 [95,29; 95,93]	96,34 [96,00; 96,69]
B2-4	92,50 [91,62; 93,45]	94,55 [94,03; 95,04]	95,94 [95,47; 96,32]	96,22 [95,71; 96,67]
B2-8	92,66 [91,82; 93,45]	94,76 [94,49; 95,07]	95,90 [95,40; 96,33]	96,10 [95,46; 96,68]
Q-4	90,90 [89,51; 92,05]	94,16 [92,91; 95,27]	95,96 [95,62; 96,30]	96,24 [95,90; 96,57]
Q-8	92,33 [91,02; 93,54]	94,67 [93,80; 95,25]	95,76 [95,13; 96,30]	96,29 [95,84; 96,72]
QF-4	90,86 [89,80; 91,90]	93,90 [92,70; 95,02]	95,90 [95,54; 96,24]	96,00 [95,49; 96,55]
QF-8	92,17 [90,77; 93,44]	94,62 [93,75; 95,23]	95,99 [95,47; 96,45]	96,19 [95,67; 96,68]

Tabella 5.1: Macro-F1 sul test binario, moltiplicata per 100: media e IC95% bootstrap sui dieci seed. *Full* corrisponde a 1 876 immagini di training. Le otto configurazioni sono tutte riportate, senza selezione del miglior seed.

La riduzione dei dati rende più visibili alcune differenze. Con 100 immagini, Q-4 raggiunge 90,90, contro 92,50 di B2-4; Q-8 raggiunge invece 92,33, vicino al 92,66 di B2-8. Nei regimi da 900 immagini e *Full* le medie di Q e B2 si avvicinano per entrambe le dimensioni. Questa descrizione non implica equivalenza statistica, che non è stata oggetto di un test con margine prestabilito.

5.2.2 Classificazione a tre classi

Nel task a tre classi le prestazioni sono inferiori per tutte le configurazioni e mostrano un aumento più ampio passando dai subset ridotti al *Full* (Tabella 5.2). B2-8 passa da 67,47 a 79,33, mentre Q-8 passa da 64,17 a 77,66. Il miglioramento descrittivo è rispettivamente di 11,86 e 13,49 pp.

Modello	100	300	900	Full
B0	66,10 [64,84; 67,45]	72,59 [71,42; 73,78]	76,85 [75,90; 77,89]	79,12 [77,99; 80,14]
B1	66,57 [64,88; 68,48]	73,21 [72,16; 74,31]	77,31 [76,47; 78,12]	79,92 [78,98; 80,79]
B2-4	67,44 [66,46; 68,38]	73,36 [72,16; 74,64]	76,59 [75,86; 77,41]	79,00 [77,90; 80,06]
B2-8	67,47 [66,20; 68,66]	73,48 [72,51; 74,35]	76,64 [75,88; 77,59]	79,33 [78,34; 80,24]
Q-4	64,55 [62,67; 66,45]	71,02 [69,21; 72,73]	75,74 [74,94; 76,48]	78,27 [77,18; 79,20]
Q-8	64,17 [62,90; 65,38]	70,33 [69,26; 71,58]	74,39 [72,45; 76,13]	77,66 [76,86; 78,50]
QF-4	64,46 [62,42; 66,46]	70,10 [68,27; 71,95]	75,07 [74,10; 75,97]	78,12 [77,08; 79,12]
QF-8	63,58 [61,91; 65,11]	70,02 [68,87; 71,31]	74,42 [72,45; 76,22]	77,41 [76,42; 78,47]

Tabella 5.2: Macro-F1 sul test a tre classi, moltiplicata per 100: media e IC95% bootstrap sui dieci seed. *Full* corrisponde a 2 814 immagini di training.

B2 mantiene una media superiore a Q in tutti e quattro i regimi, sia nella configurazione a quattro dimensioni sia in quella a otto. Anche B0 e B1 raggiungono sul *Full* valori superiori alle medie di Q e QF. Non vengono però introdotti test a coppie tra tutte le architetture: B0 e B1 rimangono riferimenti contestuali, con architetture e condizioni di ottimizzazione non identiche a B2.

La Figura 5.1 mette a confronto i due task per le configurazioni a otto dimensioni/qubit. Nel binario le traiettorie sono vicine, soprattutto dai 300 campioni in poi. Nel task a tre classi permane invece una separazione tra B2 e i modelli quantistici. È importante precisarne l'andamento: aumentando i dati, il divario medio Q–B2 si *riduce*, passando da −3,30 pp con 100 immagini a −1,67 pp sul *Full*; non aumenta. L'incremento della numerosità migliora quindi entrambi i modelli, senza annullare lo scarto nel protocollo osservato.

5.3 Confronto appaiato Q–B2

5.3.1 Famiglia primaria: training completo

Il confronto primario utilizza, per ogni seed, la differenza tra la Macro-F1 di Q e quella di B2 con lo stesso task e la stessa dimensione del bottleneck. Un valore negativo favorisce B2. La Tabella 5.3 riporta tutti i quattro confronti *Full*, con gli intervalli e i p-value conservati negli artefatti dell'esperimento.

Nel binario le differenze medie sono piccole e positive, ma gli intervalli includono lo zero e nessun p-value corretto è inferiore a 0,05. Non emerge quindi evidenza

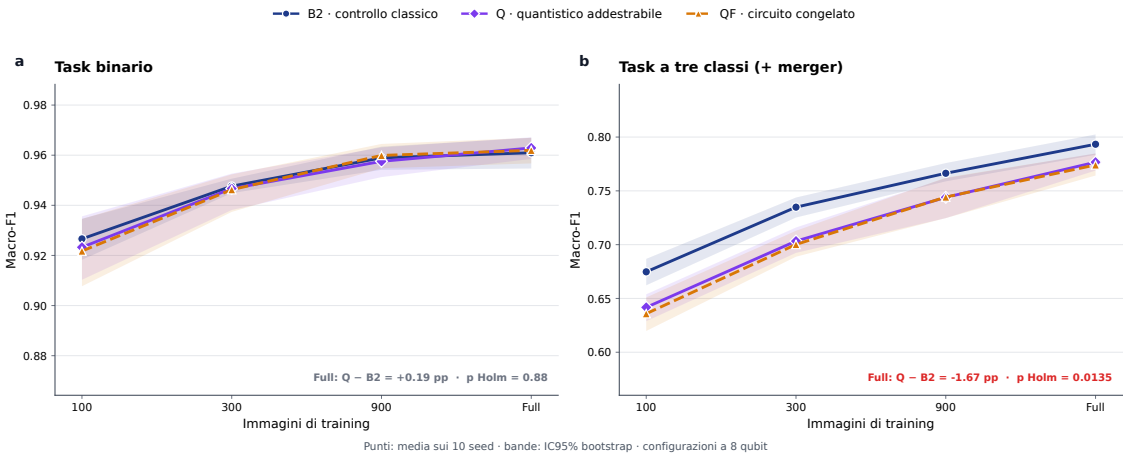


Figura 5.1: Prestazioni rispetto alla numerosità del training per B2-8, Q-8 e QF-8. Punti e linee rappresentano le medie sui dieci seed; le bande sono IC95% bootstrap. Le posizioni 100, 300, 900 e *Full* sono categoriche ed equidistanti: la pendenza dei segmenti non è un tasso di miglioramento per immagine. I pannelli adottano scale verticali diverse; *Full* contiene 1 876 immagini nel binario e 2 814 nel task a tre classi.

Task	q	Δ (pp)	IC95% (pp)	p_{Holm}	d_z
Binario	4	+0,02	[−0,29; +0,33]	0,9406	+0,04
Binario	8	+0,19	[−0,22; +0,61]	0,8797	+0,27
Tre classi	4	−0,73	[−1,27; −0,33]	0,0132	−0,87
Tre classi	8	−1,67	[−2,41; −1,02]	0,0135	−1,40

Tabella 5.3: Confronti primari Q–B2 sul *Full*. Dieci coppie per riga; Holm è applicato alla famiglia dei quattro test. Gli IC95% sono bootstrap marginali. d_z è la differenza media divisa per la deviazione standard delle differenze appaiate.

di un vantaggio di Q rispetto a B2, né la mancanza di significatività consente di dichiararli equivalenti.

Nel task a tre classi entrambi i confronti indicano invece una Macro-F1 inferiore per Q, con $p_{\text{Holm}} < 0{,}05$. La perdita media è di 0,73 pp a quattro qubit e di 1,67 pp a otto qubit. Gli intervalli sono interamente negativi. La maggiore ampiezza osservata a otto qubit è una descrizione degli effetti; non costituisce, da sola, un test della differenza tra i due effetti.

5.3.2 Famiglia secondaria: regimi low-resource

La Tabella 5.4 mostra i dodici confronti sui subset. La correzione di Holm è calcolata su tutte le dodici righe, non separatamente per task, dimensione o numerosità. Nel binario nessun confronto risulta significativo dopo questa correzione. Nel task a tre classi le differenze sono tutte negative; quelle a otto qubit risultano significative in ciascun subset, mentre quelle a quattro qubit non raggiungono la significatività.

Con 100 immagini, il contrasto binario a quattro qubit è −1,61 pp e il suo IC95% non include zero, ma il p-value corretto è 0,1632. Non è una contraddizione: intervallo marginale bootstrap e test corretto per la molteplicità non sono lo stesso

Subset	Task	q	Δ	IC95%	p_{Holm}
100	Binario	4	−1,61	[−2,62; −0,56]	0,1632
100	Binario	8	−0,33	[−1,81; +0,82]	1,0000
100	Tre classi	4	−2,88	[−4,31; −1,29]	0,1071
100	Tre classi	8	−3,30	[−4,99; −1,80]	0,0396
300	Binario	4	−0,39	[−1,42; +0,58]	1,0000
300	Binario	8	−0,10	[−0,81; +0,43]	1,0000
300	Tre classi	4	−2,34	[−3,76; −0,83]	0,1632
300	Tre classi	8	−3,15	[−4,46; −1,86]	0,0360
900	Binario	4	+0,02	[−0,38; +0,40]	1,0000
900	Binario	8	−0,14	[−0,44; +0,11]	1,0000
900	Tre classi	4	−0,85	[−1,39; −0,25]	0,1632
900	Tre classi	8	−2,24	[−3,88; −0,94]	0,0396

Tabella 5.4: Tutti i confronti secondari Q–B2. Effetti e intervalli sono espressi in punti percentuali. I p-value sono corretti con Holm congiuntamente sui dodici confronti.

criterio decisionale. Lo stesso richiamo vale per i contrasti a quattro qubit nel task a tre classi.

La Figura 5.2 raccoglie i confronti nei quattro regimi. Non si osserva un vantaggio statisticamente supportato di Q nei regimi con meno dati. A otto qubit, nel task a tre classi, la penalità media è anzi più ampia nei subset da 100 e 300 immagini rispetto al *Full*. Si tratta di un andamento descrittivo tra regimi: i test riportati valutano Q–B2 entro ciascun regime, non la significatività della sua variazione tra numerosità.

5.4 Passaggio dal binario alle tre classi

La diminuzione della Macro-F1 assoluta interessa tutti i modelli. Per isolare sul piano descrittivo la variazione del divario tra Q e B2, si considera il contrasto

$$D_s^{(\text{pp})} = 100 D_s = 100 \left[(F_{1,s}^{\text{Q}} - F_{1,s}^{\text{B2}})_{\text{tre}} - (F_{1,s}^{\text{Q}} - F_{1,s}^{\text{B2}})_{\text{binario}} \right].$$

Qui D_s è definito nella Equazione (4.17) sulla scala originale della Macro-F1. Le differenze sono costruite entro lo stesso repeat seed; il bootstrap ricampiona questi dieci contrasti, non quattro medie indipendenti. Un valore negativo indica che Q perde terreno rispetto a B2 nel task a tre classi.

Tutte le stime medie sono negative (Tabella 5.5). A otto qubit il contrasto è compreso tra circa −3,06 e −1,86 pp e gli intervalli marginali restano sotto lo zero. A quattro qubit gli effetti sono più contenuti; con 100 immagini l'intervallo attraversa lo zero. Il limite superiore molto vicino a zero per 900 immagini non va interpretato come una separazione netta tra presenza e assenza dell'effetto.

Questa analisi rende visibile una differenza relativa che sarebbe poco leggibile rappresentando soltanto il calo comune di circa venti punti della Macro-F1. Non

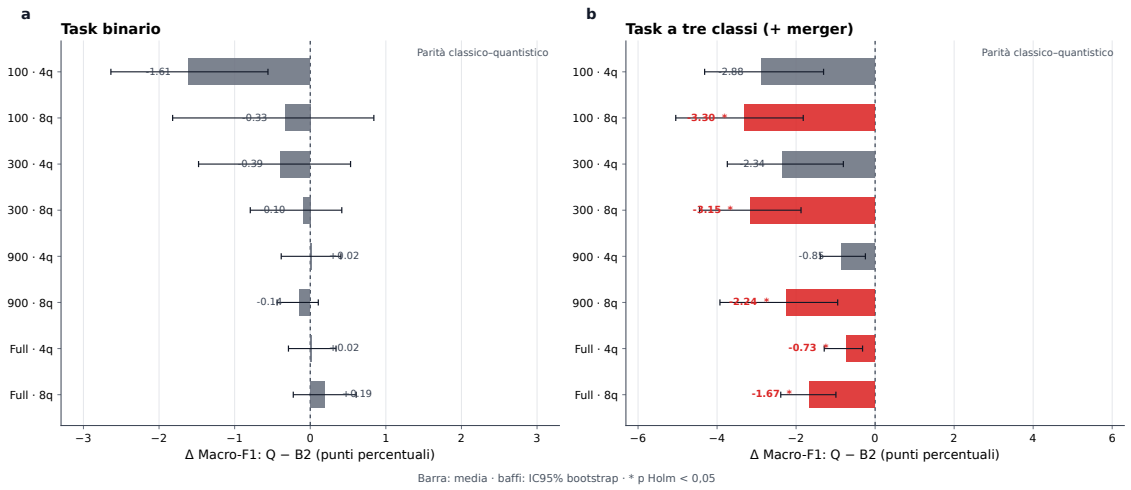


Figura 5.2: Differenze appaiate Q–B2 nei due task. Barre: differenza media in pp; baffi: IC95% bootstrap; asterisco: $p_{\text{Holm}} < 0{,}05$. I quattro confronti *Full* e i dodici sui subset appartengono a famiglie di correzione distinte. Le scale orizzontali dei pannelli sono diverse. Gli intervalli della figura sono ricampionati dal notebook grafico e possono differire lievemente da quelli archiviati nelle Tabelle 5.3 e 5.4.

Regime	4 qubit: media [IC95%]	8 qubit: media [IC95%]
100	−1,27 [−3,13; +0,86]	−2,97 [−5,17; −0,78]
300	−1,95 [−3,37; −0,46]	−3,06 [−4,61; −1,49]
900	−0,87 [−1,59; −0,02]	−2,10 [−3,54; −0,91]
Full	−0,75 [−1,42; −0,24]	−1,86 [−2,56; −1,21]

Tabella 5.5: Differenza-in-differenze tra task, in pp: media e IC95% bootstrap dei contrasti appaiati. Analisi esplorativa, senza un'ulteriore famiglia di test o correzioni di Holm.

identifica però un effetto causale dell'aggiunta della classe merger: cambiano il problema di classificazione, la composizione dei dati e, sul *Full*, anche la numerosità totale del training. La Macro-F1 dei due task è inoltre una media su un diverso numero di classi.

5.5 Analisi della classe merger

5.5.1 F1, precision e recall

La classe merger è quella con la F1 media più bassa sul *Full* per tutte le configurazioni B2, Q e QF riportate nella Tabella 5.6. Il confronto con le altre due classi permette di localizzare il divario, senza attribuirgli automaticamente una causa fisica o un problema nelle etichette.

	F1 per classe			Merger	
Modello	**Ellittiche**	**Spirali**	**Merger**	**Precision**	**Recall**
B2-4	84,99	81,76	70,27	72,68	68,23
Q-4	84,69	80,74	69,38	71,04	68,53
QF-4	84,70	80,49	69,17	71,59	67,59
B2-8	85,16	82,26	70,58	73,79	67,87
Q-8	84,61	80,39	67,99	71,63	64,97
QF-8	84,83	79,66	67,73	71,53	64,90

Tabella 5.6: Prestazioni medie per classe sul *Full* a tre classi, moltiplicate per 100. Per merger sono riportate anche precision e recall. Ogni valore è la media della metrica calcolata separatamente sui dieci test; F1 non è ricostruita dalla precision e dal recall medi.

A otto qubit, Q perde rispetto a B2 circa 2,58 pp nella F1 merger, 1,86 pp nelle spirali e 0,56 pp nelle ellittiche. Poiché la Macro-F1 è la media delle tre F1, il contributo aritmetico della classe merger al divario complessivo è circa $2{,}58/3 = 0{,}86$ pp, poco più della metà dei 1,67 pp osservati. Questo è un modo di scomporre la metrica, non una spiegazione causale degli errori.

A quattro qubit il quadro è meno concentrato sulla merger: la diminuzione della sua F1 è di 0,88 pp, mentre per le spirali è di 1,02 pp. Inoltre il recall merger di Q-4 è lievemente superiore a quello di B2-4 (68,53 contro 68,23), a fronte di una precision inferiore (71,04 contro 72,68). Non sarebbe quindi corretto descrivere entrambe le dimensioni come un'identica perdita di capacità di recuperare le merger.

5.5.2 Andamento nei subset ed errori di classificazione

La Figura 5.3 mostra che il divario sulla F1 merger è particolarmente ampio con 100 immagini e otto qubit: Q–B2 è pari a $-9{,}82$ pp, con IC95% esplorativo $[-13{,}32; -6{,}72]$. La differenza si riduce a $-4{,}82$ pp con 300 immagini, $-3{,}50$ pp con 900 e $-2{,}58$ pp sul *Full*. A quattro qubit il divario medio passa da $-4{,}47$ pp nel subset minimo a $-0{,}88$ pp sul *Full*, ma non decresce monotonamente: con 900 immagini è di soli $-0{,}32$ pp.

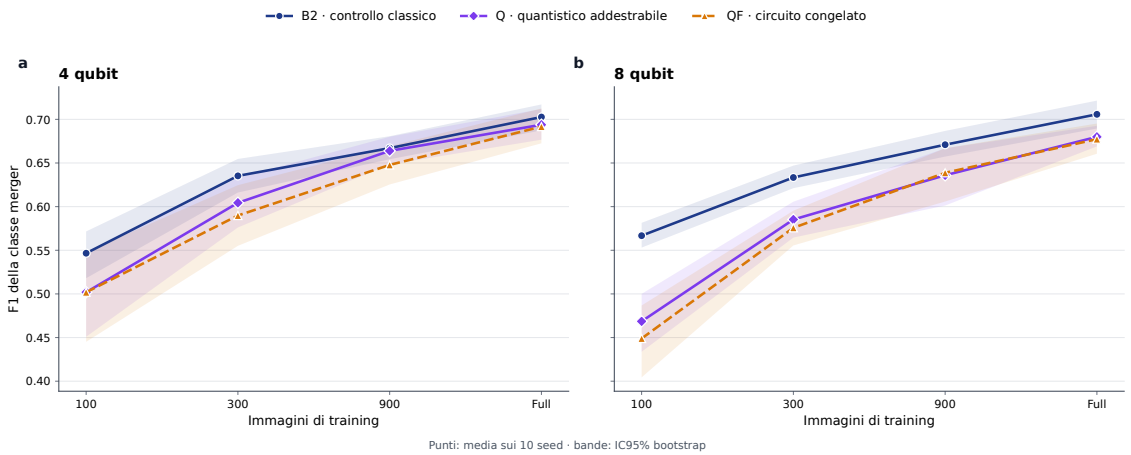


Figura 5.3: F1 della classe merger rispetto al regime di training, con pannelli separati per quattro e otto dimensioni/qubit. Le linee rappresentano le medie e le bande gli IC95% bootstrap. Le due scale verticali coincidono. La figura descrive la F1 di una singola classe, non la Macro-F1 dell'intero task.

Le matrici di confusione normalizzate forniscono un riscontro più specifico sugli errori del *Full*. Per ogni modello sono state mediate le matrici normalizzate per riga dei dieci seed, senza trattare come oggetti distinti le ricomparse di una stessa galassia in holdout diversi. In B2-8, in media, il 17,44% delle merger è classificato come spirale; in Q-8 la quota sale al 20,68%. La quota di merger assegnate alle ellittiche è invece simile: 14,69% in B2-8 e 14,35% in Q-8. La diminuzione del recall merger a otto qubit si associa dunque, in questi tassi medi, soprattutto a più assegnazioni alla classe spirale.

A quattro qubit, invece, le merger assegnate alle spirali sono il 18,78% per B2-4 e il 17,91% per Q-4. Aumenta la confusione nella direzione opposta: le spirali assegnate alla classe merger passano dal 13,69% al 16,12%. Questo andamento è coerente con la minore precision merger di Q-4. Le percentuali descrivono tassi medi per classe vera, non percentuali sull'intero dataset.

5.6 Contributo dell'addestramento quantistico e dimensionalità

5.6.1 Circuito addestrabile rispetto al circuito congelato

Il confronto Q–QF valuta quanto cambi la prestazione quando i pesi del circuito vengono ottimizzati, mantenendo addestrabili le componenti classiche in entrambi i modelli. QF non è quindi un classificatore interamente congelato.

Sul *Full* il vantaggio medio di Q è contenuto: nel binario è di 0,23 pp a quattro qubit e 0,10 pp a otto; nel task a tre classi è di 0,15 e 0,26 pp. Tutti i quattro intervalli bootstrap *Full* includono lo zero (Figura 5.4). Questi dati non documentano un beneficio netto e uniforme dell'ottimizzazione dei pesi circuitali.

Alcuni subset mostrano effetti più favorevoli a Q. Nel task a tre classi a quattro qubit, Q–QF è +0,92 pp con 300 immagini, con IC95% circa [+0,24; +1,70], e +0,67 pp con 900, con IC95% circa [+0,21; +1,30]. Nel binario a otto qubit e 100 immagini il vantaggio è più piccolo, +0,15 pp, con IC95% circa [+0,04; +0,28]. Al contrario,

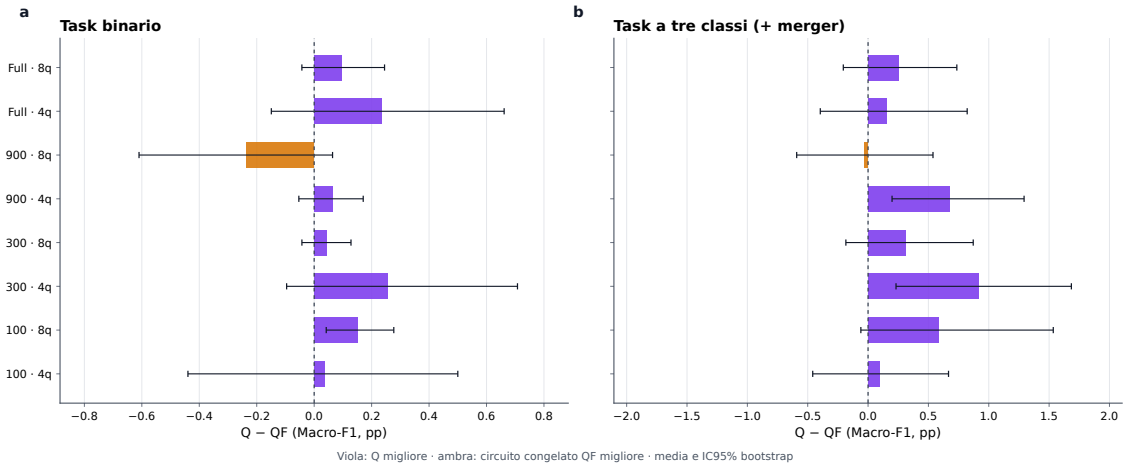


Figura 5.4: Confronto esplorativo Q–QF: differenza media appaiata di Macro-F1 in pp e IC95% bootstrap. Valori positivi favoriscono Q. I colori indicano il segno dell'effetto, non la significatività. Le scale orizzontali dei due task sono diverse. Non sono introdotti nuovi p-value per questi confronti.

Q-8 nel binario con 900 immagini è mediamente inferiore a QF-8 di 0,24 pp, con intervallo che include lo zero. Sono evidenze esplorative e non una nuova serie di risultati confermativi selezionati in base agli intervalli più favorevoli.

5.6.2 Da quattro a otto dimensioni/qubit

La sensibilità alla dimensione è riassunta nella Figura 5.5. Nel binario con 100 immagini, Q-8 supera Q-4 di 1,43 pp; sul *Full* la differenza si riduce a 0,05 pp. Nel task a tre classi, invece, Q-8 ha una media inferiore a Q-4 in tutti i regimi: le differenze $8-4$ sono circa $-0{,}38$, $-0{,}69$, $-1{,}34$ e $-0{,}61$ pp per 100, 300, 900 e *Full*. Per B2, nello stesso task, le differenze sono piccole e positive.

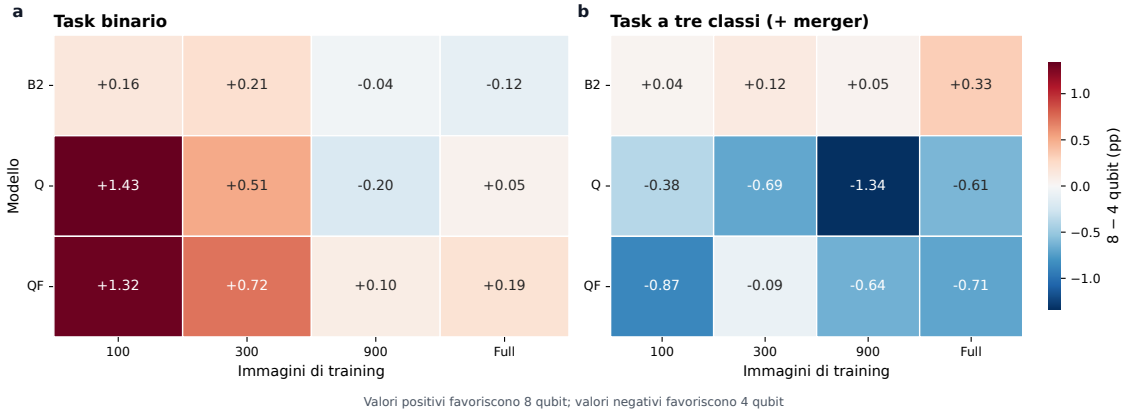


Figura 5.5: Variazione media della Macro-F1 passando da quattro a otto dimensioni/-qubit, in pp. Valori positivi favoriscono la dimensione otto. La heatmap è una sintesi descrittiva senza intervalli o marcature di significatività. Per B2 varia la dimensione del bottleneck classico; per Q e QF cambiano anche il circuito e le dimensioni dei livelli classici collegati.

Task	Modello	ECE	Brier score	Log-loss
Binario	B2-4	0,0189	0,0603	0,1205
	Q-4	0,0158	0,0610	0,1172
	B2-8	0,0205	0,0631	0,1258
	Q-8	0,0158	0,0598	0,1160
Tre classi	B2-4	0,0495	0,3024	0,5137
	Q-4	0,0508	0,3132	0,5361
	B2-8	0,0570	0,2970	0,5078
	Q-8	0,0432	0,3185	0,5417

Tabella 5.7: Metriche probabilistiche medie sul test *Full*, senza ricalibrazione post-hoc. Dieci seed per configurazione. I valori sono nella scala originale delle metriche, non moltiplicati per 100. Sintesi descrittiva, senza test aggiuntivi.

L'aumento della dimensione non coincide dunque con un incremento sistematico delle prestazioni. Questa osservazione riguarda le configurazioni effettivamente confrontate: come precisato nel Capitolo 4, il passaggio da quattro a otto qubit modifica anche la proiezione classica e il classificatore finale. Non isola l'effetto del solo numero di qubit.

5.7 Qualità delle probabilità e calibrazione

La Macro-F1 valuta le decisioni di classe, ma non esaurisce l'analisi delle probabilità prodotte dal modello. La Tabella 5.7 riporta ECE, Brier score e log-loss medi sul *Full* per B2 e Q. Valori più bassi sono preferibili, ma le tre quantità misurano aspetti diversi; in particolare Brier score e log-loss non sono misure di sola calibrazione [8]. L'ECE confronta invece accuratezza e confidenza aggregate in intervalli [9].

Nel binario, Q mostra ECE e log-loss medi inferiori a B2 per entrambe le dimensioni; il Brier score è lievemente superiore per Q-4 e inferiore per Q-8. Nel task a tre classi, Brier score e log-loss sono maggiori per Q in entrambe le configurazioni. L'ECE non segue uniformemente questo ordinamento: Q-8 ha un ECE medio di 0,0432, inferiore al 0,0570 di B2-8, pur avendo una Macro-F1 inferiore e peggiori Brier score e log-loss.

Non vi è contraddizione tra questi risultati: una minore discrepanza media tra confidenza e accuratezza nei bin dell'ECE non garantisce una migliore discriminazione delle classi o una migliore qualità probabilistica secondo ogni criterio. Non si utilizza quindi il solo ECE per ribaltare il confronto sulla Macro-F1, né un reliability diagram di un singolo seed per caratterizzare un'intera architettura. I valori assoluti delle metriche probabilistiche tra binario e tre classi non vanno letti come se composizione e numero di classi fossero invariati.

	Binario		Tre classi	
Modello	**Training**	**Test**	**Training**	**Test**
B2-4	23,88	0,192	41,90	0,287
Q-4	250,27	2,253	441,80	3,456
QF-4	209,17	2,188	380,25	3,273
B2-8	23,31	0,195	42,41	0,279
Q-8	442,67	4,211	854,89	6,557
QF-8	361,37	4,181	668,88	6,692

Tabella 5.8: Tempi mediani sul *Full* in secondi, sui dieci seed. Training: somma dei tempi di epoca; test: tempo di predizione su 938 esempi nel binario e 1 407 nel task a tre classi. Le misure escludono la costruzione della cache di feature e non rappresentano latenze end-to-end delle immagini.

5.8 Prestazioni e costo computazionale

5.8.1 Tempi registrati e ambito del confronto

I tempi sono confrontati tra modelli dello stesso regime, secondo le condizioni di esecuzione descritte nella Sezione 4.9.2. Le traiettorie tra regimi hanno funzione descrittiva e non misurano lo scaling del costo rispetto alla sola numerosità del training.

La Tabella 5.8 riporta i tempi mediani del *Full*. Il tempo di training è la somma dei tempi di epoca registrati: non include estrazione iniziale delle feature, salvataggio successivo dei checkpoint, valutazione finale o trasferimenti degli archivi. Il tempo di predizione qui riportato è invece lo specifico campo `test_inference_seconds`, riferito all'intero test dopo il ripristino del checkpoint selezionato. Non è il campo `inference_seconds` delle tabelle intermedie, che si riferisce alla validation.

I tempi di Q sono maggiori di quelli di B2 sia durante il training sia durante la predizione sul test. QF riduce il tempo mediano di training rispetto a Q nelle configurazioni *Full*, ma resta molto più costoso del controllo classico. Il congelamento dei pesi circuitali non elimina infatti l'esecuzione del circuito né la propagazione del gradiente necessaria ad addestrare la proiezione che lo precede.

5.8.2 Rapporti appaiati e compromesso prestazioni–tempo

La Tabella 5.9 riporta la mediana dei dieci rapporti $t_{\mathrm{Q},s}/t_{\mathrm{B2},s}$, non il rapporto tra i tempi mediani della tabella precedente. I rapporti mediani di training vanno da circa 10 a 15 a quattro qubit e da circa 19 a 26 a otto qubit.

La Figura 5.6 combina Macro-F1 media e tempo di training mediano. Nel task a tre classi, entro ogni regime, B2 raggiunge una prestazione media maggiore con un tempo mediano inferiore rispetto alle corrispondenti configurazioni Q e QF. Nel binario alcuni punti quantistici hanno una Macro-F1 media lievemente superiore, ma a fronte di un costo temporale nettamente maggiore. Non è dunque corretto descrivere B2 come strettamente dominante in ogni singolo confronto binario soltanto sulla base del grafico.

Task	q	100	300	900	Full
Binario	4	14,63	11,03	10,15	10,19
Binario	8	25,66	19,10	18,97	19,26
Tre classi	4	12,18	11,14	11,11	10,58
Tre classi	8	21,44	21,56	23,95	18,58

Tabella 5.9: Mediana dei rapporti appaiati di tempo di training Q/B2. Un valore 10 indica un tempo dieci volte quello di B2 secondo questa statistica.

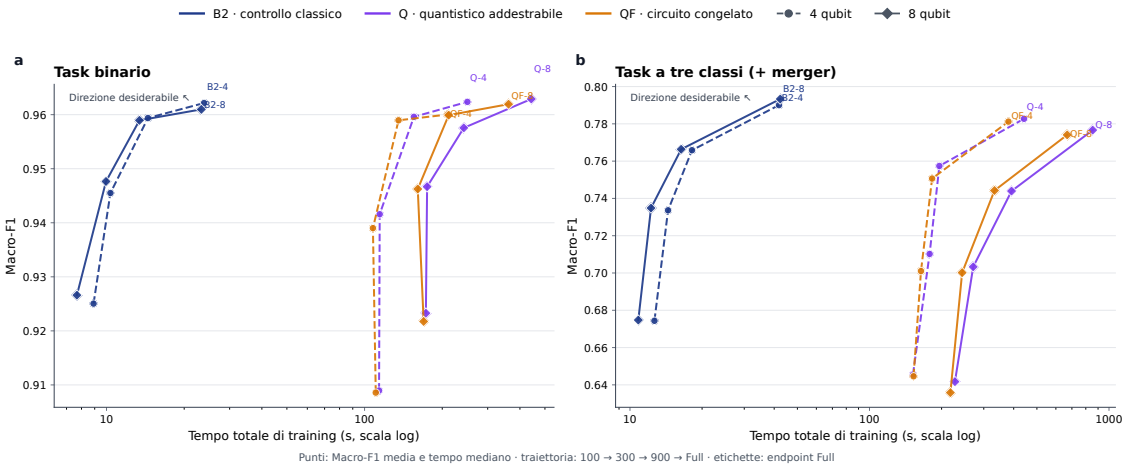


Figura 5.6: Prestazioni e tempo di training osservato: ciascun punto combina la Macro-F1 media e il tempo mediano delle dieci run di una configurazione. Le linee collegano, in ordine, 100, 300, 900 e Full; le etichette identificano l'estremo Full. L'asse dei tempi è logaritmico.

L'early stopping contribuisce ai tempi complessivi, che dipendono anche dal numero di epoche effettivamente eseguite. Le differenze non possono essere attribuite interamente al costo di una singola valutazione circuitale. Infine, tutti questi risultati riguardano il simulatore classico `default.qubit`: non misurano tempi di una QPU, costi di accesso all'hardware quantistico o consumi energetici.

5.9 Sintesi delle evidenze

Nel protocollo considerato, le prestazioni medie di tutte le configurazioni crescono all'aumentare dei dati di training. Sul *Full* binario i modelli raggiungono Macro-F1 vicine a 0,96, senza evidenza di un vantaggio di Q rispetto a B2 nei confronti primari. Nel task a tre classi, invece, Q presenta una Macro-F1 inferiore a B2 per entrambe le dimensioni, con significatività secondo la procedura appaiata e la correzione adottate.

Nei regimi low-resource non emerge il vantaggio quantistico ipotizzato: a otto qubit, nel task a tre classi, le perdite medie sono maggiori di quelle osservate sul *Full* e risultano significative nella famiglia secondaria. L'analisi merger localizza una parte importante del divario, soprattutto a otto qubit, senza spiegare da sola tutti gli errori. Il confronto con QF mostra benefici dell'addestramento circuitale piccoli

sul *Full* e dipendenti dal regime nei subset. Aumentare da quattro a otto qubit non offre un miglioramento sistematico della Macro-F1.

Le metriche probabilistiche aggiungono un quadro non riducibile al solo ordinamento della Macro-F1; i costi registrati mostrano invece un aumento consistente del tempo richiesto dai modelli quantistici simulati rispetto a B2. Queste evidenze circoscrivono il risultato sperimentale alle architetture, ai dati e alle condizioni qui analizzati: non costituiscono un'affermazione generale sull'impossibilità di un vantaggio del machine learning quantistico.

Capitolo 6

Discussione

Le teste ibride ottengono buone prestazioni sulla rappresentazione estratta da ResNet18, ma non superano il controllo classico B2 nei confronti statistici del Capitolo 5. Per interpretare questo risultato occorre considerare separatamente la difficoltà del task, la disponibilità dei dati e il costo. La discussione segue le domande di ricerca del Sezione 1.4; le possibili spiegazioni sono distinte dai meccanismi effettivamente verificati.

6.1 Confronto principale e ruolo della rappresentazione

Per RQ1, i dati non forniscono evidenza di un miglioramento di Q rispetto a B2. Sul *Full* binario le differenze medie sono piccole, pari a +0,02 e +0,19 punti percentuali per quattro e otto qubit, senza significatività dopo Holm. Sul *Full* a tre classi si osservano invece differenze di −0,73 e −1,67 pp, significative secondo la procedura adottata. L'assenza di significatività nel primo caso non dimostra equivalenza, che richiederebbe un margine definito e un test dedicato.

Le buone prestazioni di B0 e B1 aiutano a interpretare questo quadro. Una parte rilevante dell'informazione discriminativa è già contenuta nelle feature classiche. La componente quantistica non deve apprendere una rappresentazione direttamente dai pixel, ma rielaborare una rappresentazione preesistente dopo una forte compressione. La domanda non riguarda pertanto la superiorità di un intero sistema di visione quantistico, bensì il valore aggiunto di una particolare testa.

B2 conserva prestazioni competitive con un bottleneck di sole quattro o otto componenti. Ciò indica che, nelle condizioni osservate, la compressione non impedisce di ottenere buoni risultati. Non dimostra che le altre componenti delle feature siano sempre inutili, né che qualsiasi proiezione verso poche dimensioni sarebbe sufficiente: la proiezione è addestrata insieme al classificatore.

Nel binario il livello prossimo a 0,96 di Macro-F1 è compatibile con una situazione in cui il margine di miglioramento misurabile è contenuto. L'espressione effetto soffitto va tuttavia intesa come interpretazione: non sono noti l'errore irriducibile del problema o il massimo conseguibile con le etichette disponibili. La convergenza delle medie non basta a identificarli.

6.2 Complessità del task e classe merger

La risposta a RQ2 è che il divario relativo diventa più sfavorevole a Q nel passaggio alle tre classi. La differenza-in-differenze sul *Full* è di circa −0,75 pp a quattro qubit e −1,86 pp a otto. Questo contrasto è più informativo del solo calo assoluto di Macro-F1, che interessa tutti i modelli.

Non si tratta però di un effetto causale isolato dell'aggiunta dei merger. Cambiano il numero di classi, la composizione degli esempi e, sul *Full*, la numerosità del training. Inoltre, la Macro-F1 media due oppure tre F1 per classe. La conclusione sostenibile è quindi una variazione osservata del confronto relativo tra task, non la quantificazione di una penalità fisica attribuibile a una sola categoria.

I sistemi etichettati come merger costituiscono un banco di prova utile: formano la classe con F1 media più bassa sul *Full* per B2, Q e QF. A otto qubit, il loro contributo aritmetico rappresenta poco più della metà dello scarto complessivo Q–B2 nella Macro-F1. Le matrici di confusione mostrano anche più merger assegnate alle spirali da Q-8. A quattro qubit, invece, il quadro include una perdita di precision merger con recall lievemente superiore al controllo. Non esiste quindi un'unica modalità di errore comune alle due configurazioni.

La maggiore eterogeneità visuale dei sistemi perturbati è una spiegazione plausibile della difficoltà condivisa dai modelli. I risultati non permettono però di distinguere quanto dipenda dalla rappresentazione congelata, dalla testa, dall'ambiguità delle etichette o dalle condizioni osservative. Attribuire gli errori direttamente all'incapacità del circuito di riconoscere specifiche strutture astronomiche richiederebbe esperimenti ulteriori.

6.3 Disponibilità dei dati e regimi low-resource

RQ3 verifica se il circuito sia particolarmente utile quando il training contiene pochi esempi. Le evidenze non sostengono questa ipotesi nel protocollo considerato. Nelle tre classi Q ha una media inferiore a B2 in tutti i regimi; a otto qubit le differenze dei tre subset rimangono significative dopo la correzione secondaria. Il divario medio passa da −3,30 pp con 100 immagini a −1,67 pp sul *Full*: cresce la prestazione di entrambi e lo scarto si riduce, senza annullarsi.

Questo andamento mostra perché sia utile non limitarsi al training completo. Le prestazioni vicine sul task binario non descrivono l'intero comportamento delle architetture; task più articolati e subset ridotti possono rendere visibili differenze attenuate altrove. La F1 merger con 100 immagini e otto qubit, inferiore in Q di circa 9,82 pp rispetto a B2, rappresenta uno di questi casi, da interpretare come analisi esplorativa di una singola classe.

L'annidamento dei subset mantiene controllata la provenienza dei dati e rende coerente il percorso da pochi esempi al *Full*. Non elimina tuttavia tutte le altre differenze: con batch e limite di epoche fissati, un dataset più piccolo produce meno aggiornamenti per epoca; l'early stopping modifica inoltre la durata effettiva. Le curve descrivono quindi il comportamento del protocollo a differenti numerosità, non un esperimento a identico numero di aggiornamenti.

6.4 Addestramento circuitale e numero di qubit

Il confronto Q–QF risponde alla prima parte di RQ4. Sul *Full* i vantaggi medi di Q sono compresi tra circa 0,10 e 0,26 pp e tutti gli intervalli includono lo zero. Non emerge dunque un beneficio netto e uniforme dell'ottimizzazione circuitale, pur in presenza di alcuni effetti esplorativi più favorevoli nei subset.

La vicinanza tra Q e QF è compatibile con un ruolo importante degli strati classici che precedono e seguono il circuito. QF può adattare gli angoli di ingresso attraverso la proiezione e modificare la decisione finale attraverso il classificatore: non è un modello privo di apprendimento. Non si può quindi dedurre che il circuito sia ignorato, che i suoi gradienti siano nulli o che la rete sia equivalente a un classificatore lineare.

La seconda parte di RQ4 riguarda la dimensionalità. Otto qubit non offrono un miglioramento sistematico: nel task a tre classi Q-8 ha una media inferiore a Q-4 in tutti i regimi, mentre nel binario con 100 esempi l'ordinamento è opposto. Più qubit non costituiscono quindi, in queste configurazioni, una garanzia di maggiore utilità predittiva.

Il passaggio da quattro a otto modifica però anche proiezione, classificatore, numero di rotazioni e collegamenti circuitali. Il confronto non identifica l'effetto separato di ciascun elemento. Una maggiore difficoltà di ottimizzazione o una diversa adeguatezza della trasformazione ai dati sono ipotesi possibili, non meccanismi dimostrati dal solo ordinamento delle medie.

In particolare, non viene diagnosticato un barren plateau. Il fenomeno descritto da McClean et al. [16] richiede condizioni e misure specifiche. Come chiarito nel metodo, il campo diagnostico denominato `quantum_gradient_norm` include anche parametri classici e non permette di isolare i gradienti degli angoli variazionali. Né la loro scomparsa né la loro adeguata ampiezza possono essere concluse da quella diagnostica aggregata.

6.5 Qualità probabilistica e costo computazionale

Le metriche probabilistiche aggiungono informazioni che la Macro-F1 non contiene. Un modello può avere decisioni meno accurate e una confidenza mediamente più coerente con la propria frequenza di successo. Questo aiuta a leggere il caso di Q-8 sulle tre classi: l'ECE medio è inferiore a quello di B2-8, ma Brier score e log-loss sono peggiori. Non è una contraddizione e non costituisce un ribaltamento del confronto predittivo. Le metriche valutano aspetti diversi e l'ECE dipende anche dal binning [9, 8].

Per RQ5 il costo osservato è nettamente sfavorevole ai modelli quantistici simulati. Sul *Full*, le mediane dei rapporti appaiati di training Q/B2 sono circa dieci a quattro qubit e diciannove a otto. Nelle tre classi B2 combina inoltre una Macro-F1 media superiore con tempi mediani inferiori. Nel binario i piccoli vantaggi medi di alcune configurazioni Q non sono statisticamente supportati e richiedono comunque un costo maggiore.

QF riduce il costo di training rispetto a Q sul *Full*, ma resta più costoso di B2. Congelare il circuito non evita la sua esecuzione né la differenziazione rispetto agli ingressi necessaria per addestrare la proiezione. La distinzione tra pesi conge-

lati e assenza di calcolo del gradiente è quindi rilevante anche dal punto di vista computazionale.

I tempi riguardano le teste simulate ed escludono l'estrazione delle feature. Il diverso ambiente di esecuzione tra regimi (Sezione 4.9.2) e il numero di epoche determinato dall'early stopping impediscono di attribuire tutte le variazioni temporali alla numerosità dei dati o al costo delle porte. Queste misure non consentono inoltre di stimare tempi o consumi di una QPU.

6.6 Relazione con la letteratura

Il lavoro conferma la praticabilità dello schema di transfer learning ibrido introdotto da Mari et al. [15]: la rappresentazione classica consente di utilizzare piccoli circuiti su immagini di dimensione elevata. Questa fattibilità è distinta dalla superiorità predittiva. Anche l'interesse per piccoli dataset documentato nel telerilevamento [20] motiva una verifica, ma non implica che lo stesso comportamento debba emergere sulle galassie.

I risultati sono coerenti con l'esigenza metodologica evidenziata da Bowles et al. [3]: la scelta di baseline e condizioni sperimentali influenza ciò che si può attribuire alla componente quantistica. Qui B2 è particolarmente informativo perché conserva il bottleneck e gli strati classici di interfaccia senza inserire il circuito.

Questa coerenza non rende equivalenti gli esperimenti. Dataset, encoding, ansatz, ottimizzatori e criteri di selezione differiscono tra gli studi. Il contributo della tesi è un'evidenza documentata su un preciso problema applicativo, non una confutazione generale delle possibilità del quantum machine learning.

6.7 Limiti e minacce alla validità

6.7.1 Campione, etichette e generalizzazione esterna

Il dataset è un campione selezionato e bilanciato, non una rappresentazione delle frequenze morfologiche di una survey completa. Le soglie sui voti definiscono classi operative e possono privilegiare esempi con maggiore accordo. Le metriche ottenute non determinano quindi direttamente le prestazioni su popolazioni con prevalenze, qualità osservative o livelli di ambiguità diversi.

Le partizioni separano gli identificativi degli oggetti, ma non sono costruite raggruppando sistemi fisici o regioni di cielo. L'unicità degli identificativi non garantisce l'indipendenza astronomica di tutti gli esempi. Una validazione esterna e controlli sulle eventuali correlazioni spaziali rafforzerebbero la valutazione della generalizzazione.

6.7.2 Rappresentazione, iperparametri e ambito architetturale

Il backbone congelato rende il confronto più controllato, ma limita tutte le teste all'informazione disponibile nelle feature estratte. Non viene studiato se il fine-tuning sul dominio galattico cambi il confronto Q–B2. I risultati riguardano angle

encoding singolo, profondità due e quattro oppure otto qubit; non includono altre famiglie di circuiti, rumore fisico o misure a shot finiti.

Gli iperparametri fissati favoriscono la comparabilità ma non equivalgono a una ricerca esaustiva del migliore assetto per ogni architettura. Una configurazione condivisa può essere più adatta a un modello che a un altro. B0 e B1 usano inoltre batch diversi dal confronto principale: le loro prestazioni offrono contesto, non isolano esclusivamente l'effetto della forma della testa.

6.7.3 Ripetizioni e inferenza statistica

Le dieci ripetizioni condividono il dataset e possono includere gli stessi oggetti in test differenti. Non sono dieci campioni astronomici indipendenti. Il bootstrap sui seed e il test sign-flip non modellano esplicitamente questa dipendenza, mentre la correzione di Holm tratta la molteplicità e non corregge le assunzioni dei test di partenza. Le cautele discusse da Nadeau e Bengio [17] restano quindi pertinenti.

L'appaiamento riduce la confusione dovuta a confronti su split diversi, ma non elimina questi limiti. Intervalli, p-value e dimensioni dell'effetto devono essere letti insieme, distinguendo evidenze primarie e osservazioni esplorative. Il numero complessivo di 640 run non va scambiato per 640 repliche indipendenti di ciascun confronto: ogni contrasto utilizza dieci coppie.

6.7.4 Audit, casi particolari e interpretabilità

La conservazione di predizioni, checkpoint e cronologie consente di controllare la coerenza degli aggregati e di esaminare casi particolari. Un seed favorevole o un'immagine classificata correttamente soltanto da Q può suggerire un'analisi, ma non sostituisce il confronto aggregato e non giustifica l'esclusione di run meno favorevoli.

Analogamente, una mappa di attribuzione visuale evidenzia contributi locali alla risposta del modello secondo il metodo utilizzato, non una spiegazione causale completa della decisione. Le analisi qualitative devono essere accompagnate da criteri espliciti di selezione degli esempi e non usate per trasformare un caso illustrativo in una proprietà generale dell'architettura.

6.8 Sintesi interpretativa

Il quadro osservato distingue la capacità di classificare dall'utilità di introdurre il circuito. Le teste ibride raggiungono prestazioni elevate sul binario, ma il controllo classico ottiene risultati vicini con costi inferiori. Nelle tre classi e soprattutto in alcuni regimi ridotti il divario diventa più sfavorevole a Q. L'addestramento circuitale e l'aumento dei qubit non offrono benefici uniformi.

Per le configurazioni studiate, il costo aggiuntivo non è accompagnato da un vantaggio predittivo dimostrato. Una prosecuzione motivata del lavoro è verificare quali trasformazioni siano adatte alle feature disponibili e quanto l'ottimizzazione riesca a sfruttarle, prima di aumentare ulteriormente la complessità del circuito. È una direzione di ricerca suggerita dagli esperimenti, non una conclusione generale sull'utilità del quantum machine learning.

Capitolo 7

Conclusioni e sviluppi futuri

7.1 Sintesi del lavoro

In questo lavoro ho confrontato teste classiche e ibride classico-quantistiche per la classificazione morfologica delle galassie. Il dataset bilanciato di 5 628 immagini ha permesso di definire due task e di esaminare il ruolo della disponibilità dei dati attraverso subset stratificati del training. La matrice finale comprende 640 run, organizzate su dieci ripetizioni di holdout stratificato.

La rappresentazione condivisa di ResNet18 ha consentito di concentrare l'analisi sulle teste. Le baseline B0 e B1 hanno fornito riferimenti classici; B2 ha controllato la compressione a quattro o otto componenti; Q e QF hanno distinto l'inserimento del circuito dall'addestramento dei suoi parametri. Prestazioni, incertezza, errori per classe e tempi sono stati esaminati congiuntamente.

Sul *Full* binario le architetture raggiungono Macro-F1 prossime a 0,96, senza evidenza di un vantaggio di Q rispetto a B2. Sul *Full* a tre classi Q presenta invece una perdita media di 0,73 pp a quattro qubit e 1,67 pp a otto, significativa secondo i test e la correzione adottati. I regimi con pochi dati non mostrano il beneficio quantistico ipotizzato; l'analisi merger rende visibile una parte importante delle difficoltà, soprattutto a otto qubit.

Il contributo dell'addestramento circuitale risulta contenuto sul *Full* e dipendente dal regime nei subset. L'aumento dei qubit non determina miglioramenti sistematici. I tempi dei modelli quantistici simulati sono invece sensibilmente maggiori di quelli del controllo classico. Le conclusioni restano circoscritte a dataset, rappresentazione, circuiti e protocollo considerati.

7.2 Contributi e valore del confronto

Il risultato del lavoro è un confronto riproducibile su dati astronomici. Immagini, partizioni, configurazioni e predizioni rimangono collegate negli artefatti, consentendo di risalire dalle metriche aggregate alle singole esecuzioni.

La combinazione di controlli classici, circuito congelato e regimi di dati rende il risultato più informativo di una sola misura di accuratezza. Permette di distinguere ciò che il modello ibrido riesce a fare da ciò che apporta rispetto alle alternative. Nelle condizioni esaminate, il circuito non offre un miglioramento predittivo che compensi il maggiore costo osservato.

Il protocollo costituisce inoltre una base riutilizzabile per valutare modifiche successive. Nuove rappresentazioni o circuiti possono essere confrontati mantenendo criteri espliciti di appaiamento e una distinzione tra analisi confermative ed esplorative.

7.3 Sviluppi futuri

7.3.1 Validazione esterna e robustezza del protocollo

La priorità è verificare la generalizzazione su un campione indipendente, possibilmente con condizioni osservative o prevalenze diverse. Partizioni per regione di cielo o sistema fisico aiuterebbero a controllare correlazioni non eliminate dalla sola separazione degli identificativi. Analisi di sensibilità alle soglie di etichettatura potrebbero inoltre chiarire quanto il confronto dipenda dalla selezione di esempi più o meno ambigui.

Sul piano statistico, ulteriori valutazioni dovrebbero considerare esplicitamente la dipendenza tra split e definire in anticipo famiglie di confronti e differenze di interesse pratico. Se l'obiettivo fosse dimostrare che due modelli hanno prestazioni sufficientemente vicine, servirebbe un protocollo di equivalenza o non inferiorità, non la sola assenza di significatività.

7.3.2 Rappresentazione e ottimizzazione

Una seconda direzione riguarda l'adeguatezza delle feature al dominio galattico. Backbone preaddestrati su immagini astronomiche o un fine-tuning controllato potrebbero cambiare la qualità della rappresentazione disponibile alle teste. Ogni modifica dovrebbe essere applicata anche ai controlli classici per non attribuire al circuito un beneficio dovuto all'estrattore.

È inoltre utile confrontare strategie di ottimizzazione con budget di ricerca espliciti e comparabili, distinguendo numero di epoche, aggiornamenti e tempo disponibile. Questo permetterebbe di verificare se gli iperparametri condivisi abbiano favorito alcune teste e se una diversa ottimizzazione cambi il divario osservato.

7.3.3 Ablazioni circuitali e diagnostiche mirate

Le modifiche al circuito dovrebbero rispondere a ipotesi specifiche: cambiare profondità, collegamenti o encoding separatamente è più informativo che aumentare simultaneamente tutte le componenti. Il data re-uploading, non usato nel circuito principale, rappresenta una possibile estensione da confrontare con controlli classici adeguati.

Per comprendere il ruolo dell'addestramento quantistico occorrerebbe registrare separatamente gradienti e variazioni dei soli parametri circuitali. Esperimenti con circuito senza entangling gate e analisi della sensibilità agli ingressi potrebbero verificare quale parte della trasformazione sia effettivamente utile. Si tratterebbe di nuovi esperimenti, non di spiegazioni già dimostrate dai risultati disponibili.

7.3.4 Costo e condizioni di esecuzione realistiche

Un benchmark su hardware costante, con misure end-to-end e separazione tra estrazione delle feature, training e inferenza, renderebbe più completa l'analisi dei costi. L'introduzione di shot finiti e rumore consentirebbe poi di studiare la sensibilità delle predizioni a condizioni più vicine all'esecuzione fisica.

Un'eventuale sperimentazione su QPU richiederebbe di misurare anche preparazione, compilazione, numero di valutazioni e costi di accesso, evitando di trasferire direttamente i tempi del simulatore all'hardware quantistico. Il criterio resterebbe il beneficio ottenuto rispetto a risorse e prestazioni dei controlli classici.

7.4 Considerazione conclusiva

Gli esperimenti mostrano che piccoli circuiti quantistici possono essere integrati nella pipeline e raggiungere buone prestazioni, ma che questo non basta a renderli preferibili al controllo classico. Con le feature e le condizioni adottate, B2 offre un compromesso più favorevole tra prestazioni e tempo. Il risultato riguarda le architetture valutate e non esclude benefici in altri contesti. Gli sviluppi successivi dovranno verificare quali modifiche alla rappresentazione, al circuito o all'ottimizzazione cambino questo confronto, mantenendo controlli e criteri di valutazione espliciti.

Appendice A

Query di estrazione del catalogo

La query seguente documenta la selezione iniziale effettuata tramite CasJobs. I nomi delle colonne esportate coincidono con quelli utilizzati dalla pipeline locale. Il vincolo di etichetta univoca descritto nella Sezione 3.2 viene applicato dopo l'esportazione.

```
SELECT
    p.objid,
    p.ra,
    p.dec,
    z.p_el_debiased AS prob_elliptical,
    z.p_cs_debiased AS prob_spiral,
    z.p_mg AS prob_merger,
    s.z AS redshift
INTO mydb.GalaxyCandidates_Final
FROM PhotoObj AS p
JOIN zooSpec AS z ON p.objid = z.objid
JOIN SpecObj AS s ON p.objid = s.bestObjID
WHERE
    p.clean = 1
    AND p.type = 3
    AND p.g BETWEEN 14 AND 17.5
    AND s.z BETWEEN 0.005 AND 0.1
    AND (
        z.p_el_debiased > 0.8
        OR z.p_cs_debiased > 0.8
        OR z.p_mg > 0.4
    )
```

Il CSV locale non conserva `clean`, `type` e g. La verifica retrospettiva di questi vincoli richiede pertanto l'accesso al catalogo sorgente, non il solo manifest finale.

Appendice B

Codice del confronto appaiato

I frammenti seguenti, estratti dalla funzione `paired_model_comparison` nel modulo `evaluation/statistics.py`, illustrano i passaggi chiave dell'analisi statistica (con import e controlli preliminari omessi e ritorni a capo adattati alla pagina). Il chiamante filtra preventivamente task e numero di qubit, assegnando Q come `model_a` e B2 come `model_b`. Il confronto primario riguarda il regime *Full*, mentre i confronti secondari sono separati per numerosità.

La prima fase costruisce le coppie di confronto e verifica l'assenza di osservazioni duplicate:

```
    pairing_keys = [
        key for key in (seed_column, "fold", "repeat", "subset_size")
        if key in frame.columns
    ]
    selected = frame.loc[
        frame["model"].isin([model_a, model_b]),
        pairing_keys + ["model", metric]
    ]
    if selected.duplicated(pairing_keys + ["model"]).any():
        raise ValueError("Esistono più risultati per la stessa coppia
        ↪  modello/fold/seed")
    paired = selected.pivot(
        index=pairing_keys, columns="model", values=metric
    ).dropna()
```

Il campo `fold` è conservato negli artefatti ma vale costantemente 1 (non indica una cross-validation completa). Una volta accertata la presenza di coppie complete, la procedura raggruppa le differenze per seed ed esegue il bootstrap percentile sulla media delle differenze appaiate (dieci unità di ricampionamento per contrasto):

```
    paired_differences = (
        (paired[model_a] - paired[model_b])
        .rename("difference").reset_index()
    )
    inference_values = (
        paired_differences.groupby(seed_column, sort=True)["difference"]
        .mean().to_numpy(dtype=np.float64)
    )
```

```
    rng = np.random.default_rng(seed)
    bootstrap_indices = rng.integers(
        0, len(inference_values),
        size=(n_bootstrap, len(inference_values))
    )
    bootstrap_means = inference_values[bootstrap_indices].mean(axis=1)
    confidence_interval = np.quantile(bootstrap_means, [0.025, 0.975])
```

Il ricampionamento conserva l'appaiamento Q–B2, ma non corregge la dipendenza tra holdout sovrapposti. Valgono quindi le limitazioni discusse nei capitoli metodologico e di discussione; i p-value e la correzione di Holm costituiscono passaggi distinti rispetto a questi intervalli.

Bibliografia

[1] Abdurro'uf, Katherine Accetta, Conny Aerts, et al. The seventeenth data release of the Sloan Digital Sky Surveys: Complete release of MaNGA, MaStar, and APOGEE-2 data. *The Astrophysical Journal Supplement Series*, 259(2):35, 2022. DOI: https://doi.org/10.3847/1538-4365/ac4414.

[2] Ville Bergholm, Josh Izaac, Maria Schuld, Christian Gogolin, et al. PennyLane: Automatic differentiation of hybrid quantum-classical computations, 2018. https://arxiv.org/abs/1811.04968.

[3] Joseph Bowles, Shahnawaz Ahmed, and Maria Schuld. Better than classical? the subtle art of benchmarking quantum machine learning models, 2024. https://arxiv.org/abs/2403.07059.

[4] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78:1–3, 1950. DOI: https://api.semanticscholar.org/CorpusID:122906757.

[5] D. W. Darg, Sugata Kaviraj, C. J. Lintott, et al. Galaxy Zoo: The fraction of merging galaxies in the SDSS and their morphologies. *Monthly Notices of the Royal Astronomical Society*, 401(2):1043–1056, 2010. DOI: https://doi.org/10.1111/j.1365-2966.2009.15686.x.

[6] Sander Dieleman, Kyle W. Willett, and Joni Dambre. Rotation-invariant convolutional neural networks for galaxy morphology prediction. *Monthly Notices of the Royal Astronomical Society*, 450(2):1441–1459, 2015. DOI: https://doi.org/10.1093/mnras/stv632.

[7] Bradley Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26, 1979. DOI: https://doi.org/10.1214/aos/1176344552.

[8] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. DOI: https://doi.org/10.1198/016214506000001437.

[9] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 1321–1330. PMLR, 2017. https://proceedings.mlr.press/v70/guo17a.html.

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016. https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html.

[11] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979. https://www.jstor.org/stable/4615733.

[12] Juhyeon Kim, Joonsuk Huh, and Daniel K. Park. Classical-to-quantum convolutional neural network transfer learning. *Neurocomputing*, 555:126643, 2023. DOI: https://doi.org/10.1016/j.neucom.2023.126643.

[13] Chris Lintott, Kevin Schawinski, Steven Bamford, Anže Slosar, Kate Land, Daniel Thomas, Edd Edmondson, Karen Masters, Robert C. Nichol, M. Jordan Raddick, Alex Szalay, Dan Andreescu, Phil Murray, and Jan Vandenberg. Galaxy Zoo 1: Data release of morphological classifications for nearly 900 000 galaxies. *Monthly Notices of the Royal Astronomical Society*, 410(1):166–178, 2011. DOI: https://doi.org/10.1111/j.1365-2966.2010.17432.x.

[14] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. https://openreview.net/forum?id=Bkg6RiCqY7.

[15] Andrea Mari, Thomas R. Bromley, Josh Izaac, Maria Schuld, and Nathan Killoran. Transfer learning in hybrid classical-quantum neural networks. *Quantum*, 4:340, 2020. DOI: https://doi.org/10.22331/q-2020-10-09-340.

[16] Jarrod R. McClean, Sergio Boixo, Vadim N. Smelyanskiy, Ryan Babbush, and Hartmut Neven. Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9:4812, 2018. DOI: https://doi.org/10.1038/s41467-018-07090-4.

[17] Claude Nadeau and Yoshua Bengio. Inference for the generalization error. *Machine Learning*, 52(3):239–281, 2003. DOI: https://doi.org/10.1023/A:1024068626366.

[18] Michael A. Nielsen and Isaac L. Chuang. *Quantum Computation and Quantum Information*. Cambridge University Press, 10th anniversary edition edition, 2010. DOI: https://doi.org/10.1017/CBO9780511976667.

[19] Juri Opitz and Sebastian Burst. Macro F1 and Macro F1: Analyzing the difference between two forms of Macro F1 evaluation. *PeerJ Computer Science*, 7:e581, 2021. DOI: https://doi.org/10.48550/arXiv.1911.03347.

[20] Soronzonbold Otgonbaatar, Gottfried Schwarz, Mihai Datcu, and Dieter Kranzlmüller. Quantum transfer learning for real-world, small, and high-dimensional remotely sensed datasets. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 16:9223–9230, 2023. DOI: https://doi.org/10.1109/JSTARS.2023.3316306.

[21] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, 2019. https://papers.nips.cc/paper_files/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html.

[22] Maria Schuld, Ville Bergholm, Christian Gogolin, Josh Izaac, and Nathan Killoran. Evaluating analytic gradients on quantum hardware. *Physical Review A*, 99(3):032331, 2019. DOI: https://doi.org/10.1103/PhysRevA.99.032331.

[23] scikit-learn developers. average_precision_score — scikit-learn 1.7 documentation. https://scikit-learn.org/1.7/modules/generated/sklearn.metrics.average_precision_score.html.

[24] scikit-learn developers. f1_score — scikit-learn 1.7 documentation. https://scikit-learn.org/1.7/modules/generated/sklearn.metrics.f1_score.html.

[25] TorchVision contributors. resnet18 — TorchVision 0.23 documentation. https://docs.pytorch.org/vision/0.23/models/generated/torchvision.models.resnet18.html.

[26] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics*, 1:196–202, 1945. DOI: https://api.semanticscholar.org/CorpusID:53662922.